

Формулировка исследовательской задачи модели

- Цель исследования — разработка модели интеллектуального анализа тональности новостных потоков для выявления научно-технологических тенденций в российском информационном пространстве на основе трансформерных моделей и методов обработки текстовых данных.
- На вход системы поступают новостные публикации, извлекаемые из открытых источников. На выходе формируются оценки тональности сообщений, тематические распределения и агрегированные показатели, используемые для анализа динамики научно-технологических направлений.
- Для достижения цели реализованы этапы: сбор данных, предобработка текстов, классификация тональности с использованием дообученной трансформерной модели, а также последующий анализ результатов, включая тематическое моделирование и выявление тенденций.

Анализ и характеристика входных данных

Таблица 2 — Входные данные

Название признака	Описание	Тип данных
id	уникальный идентификатор записи	Целочисленный
date	дата публикации новости	Дата
year	Год публикации новости	Целочисленный
month	Месяц публикации новости	Целочисленный
day	День публикации новости	Целочисленный
title	Заголовок новости	Текстовый
url	Ссылка на оригинальную страницу новости	Текстовый
text	Основной текст новостного материала	Текстовый

Размер датасета: (94444, 8)

```
id      date      year  month  day  \
0    1  2006-01-03  2006      1    3
1    2  2006-01-04  2006      1    4
2    3  2006-01-04  2006      1    4
3    4  2006-01-05  2006      1    5
4    5  2006-01-06  2006      1    6
```

```
title \
0  Создатель iPod стал командором Ордена Британск...
1  Аварию шаттла Columbia пережили черви
2  Киты потеряли общий язык
3  "Рональд Рейган" вышел на первое задание
4  Китайцы тестируют пусковую установку лунного м...
```

```
url \
0  https://lenta.ru/news/2006/01/03/apple/
1  https://lenta.ru/news/2006/01/04/shuttle/
2  https://lenta.ru/news/2006/01/04/whale/
3  https://lenta.ru/news/2006/01/05/reagan/
4  https://lenta.ru/news/2006/01/06/lunar/
```

```
text
0  Джонатан Айви (Jonathan Ive), создатель культо...
1  На борту шаттла Columbia находились подопытные...
2  Киты из разных областей океана могут не понять...
3  Новейший атомный авианосец "Рональд Рейган" от...
4  Китай начал подготовку к запуску искусственног...
```

Рисунок 1 — Пример первых строк

Описание этапов разработки модели

- **Сбор данных:** выполнен автоматический сбор новостных публикаций научно-технологической тематики с использованием собственного веб-парсера, извлекающего тексты, заголовки и метаданные с новостного ресурса Lenta.ru.
- **Предобработка данных:** проведена очистка текстов, нормализация, удаление стоп-слов и лемматизация, сформирован единый корпус данных для дальнейшего анализа.
- **Проектирование модели:** определена архитектура решения, включающая блоки анализа тональности на основе трансформерной модели RuBERT, тематического моделирования и модуля выявления тенденций.
- **Реализация анализа тональности:** выполнена токенизация текстов и дообучение предобученной модели RuBERT на корпусе научно-технологических новостей для повышения качества классификации.
- **Тематическое моделирование:** реализован алгоритм LDA для выделения скрытых тематик новостного корпуса и формирования вероятностного распределения документов по темам.
- **Расчет тенденций:** разработан модуль агрегации, включающий расчет интенсивности тем, динамики их изменения и интегрального индекса научно-технологических тенденций.
- **Оценка и валидация:** проведено тестирование модели с использованием метрик качества и статистический анализ значимости выявленных трендов.

Обоснование выбора инструментальных средств разработки

Выбор инструментальных средств разработки был обусловлен требованиями к обработке больших объёмов текстовых данных и построению моделей машинного обучения.

- В качестве языка программирования выбран **Python** благодаря широкому набору библиотек для анализа данных и обработки естественного языка.
- Для реализации модели использовались библиотеки **Hugging Face Transformers** и **PyTorch**, обеспечивающие удобную работу с трансформерными архитектурами, включая **RuBERT**
- Для сбора данных применялись библиотеки **requests** и **BeautifulSoup**, что позволило реализовать парсинг новостных источников
- Для тематического моделирования использовался алгоритм, реализованный с применением библиотек **gensim** и **scikit-learn**, что позволило выделить скрытые тематические структуры в корпусе новостей и сформировать вероятностное распределение документов по темам.
- Обработка и анализ данных выполнялись с использованием **pandas** и **matplotlib**
- Разработка и тестирование осуществлялись в среде **Jupyter Notebook**, обеспечивающей наглядность и удобство проведения экспериментов

Описание реализации модели

$$T_{k,t} = w_1 z(V_{k,t}) + w_2 z(G_{k,t}) + w_3 z(S_{k,t})$$

где $V_{k,t}$ — интенсивность темы k в момент времени t ;

$G_{k,t}$ — скорость изменения тематической интенсивности;

$S_{k,t}$ — средняя тональность темы.




Рисунок 2 — Ход реализации модели

Анализ полученных результатов

НАЙДЕННЫЕ ТЕМЫ:

Тема 0:

смартфон, apple, новый, устройство, компания, пользователь, windows, специалист, microsoft, девайс,

Тема 1:

учёный, человек, исследование, исследователь, результат, процент, работа, новый, клетка, оказаться

Тема 2:

iphone, игра, новый, выйти, разработчик, компания, sony, консоль, хороший, часть

Тема 3:

спутник, запуск, космический, ракета, полёт, запустить, наса, космический аппарат, станция, роскосмос

Тема 4:

учёный, земля, звезда, планета, обнаружить, объект, масса, солнце, наблюдение, результат

Тема 5:

российский, самолёт, ракета, новый, дрон, комплекс, беспилотник, система, военный, машина

Тема 6:

компания, сша, производство, рынок, китай, страна, доллар, продажа, стоимость, поставка

Тема 7:

слово, заявить, рассказать, россия, система, отметить, специалист, технология, российский, создание

Рисунок 3 — Топ слов

Сводка по метрикам (Базовая модель):

	precision	recall	f1-score	support
NEGATIVE	0.220	0.518	0.309	18194
NEUTRAL	0.607	0.520	0.560	55621
POSITIVE	0.332	0.064	0.108	20629
accuracy			0.420	94444
macro avg	0.386	0.367	0.326	94444
weighted avg	0.473	0.420	0.413	94444

Общая точность (Accuracy): 0.4200

Сводка по метрикам (Дообученная модель):

	precision	recall	f1-score	support
NEGATIVE	0.803	0.820	0.811	18194
NEUTRAL	0.862	0.884	0.875	55621
POSITIVE	0.823	0.800	0.810	20629
accuracy			0.835	94444
macro avg	0.829	0.835	0.832	94444
weighted avg	0.842	0.853	0.848	94444

Общая точность (Accuracy): 0.8350

Рисунок 4 — Сравнение качества моделей

Анализ полученных результатов




Рисунок 5 — Изменение средней тональности по темам

Анализ полученных результатов




Рисунок 6— Индекс тенденций

Анализ полученных результатов




Рисунок 7 — Индекс тенденций

Заключение

- В ходе работы проанализированы ограничения традиционных подходов к анализу текстов и разработан конвейер обработки данных: от автоматизированного парсинга новостных потоков до расчёта показателей тональности и динамики научно-технологических тенденций.
- Ключевым элементом решения стала дообученная модель на базе RuBERT, адаптированная к корпусу русскоязычных научно-технологических новостей. Точность классификации повышена с 42% до 84% . Дополнительно реализован модуль тематического моделирования (LDA), выделивший 8 устойчивых тематических кластеров.
- Создана функционирующая система мониторинга с веб-интерфейсом, готовая к адаптации под другие источники и внедрению для аналитической поддержки принятия решений.

Пример работы модели

