

1.3 Формулировка исследовательской задачи модели

1.3.1 Определение целей, задач и критериев успешности решения

В рамках работы рассматривается задача создания модели интеллектуального анализа тональности новостных потоков научно-технологической тематики. Предполагается, что применение такой модели позволит выявлять характер информационного освещения научных разработок и технологических инициатив, а также определять общие тенденции развития научно-технологической повестки в российском информационном пространстве.

Целью работы является разработка модели интеллектуального анализа тональности новостных потоков, позволяющей автоматически определять эмоциональную окраску новостных публикаций научно-технологической тематики и использовать полученные результаты для выявления информационных тенденций.

Для достижения поставленной цели в работе решаются следующие задачи:

- формирование корпуса новостных публикаций и проведение предобработки текстовых данных;
- построение модели классификации тональности на основе современных трансформерных архитектур для русскоязычных текстов;
- формирование интегральной оценки тональности документа на основе анализа заголовка и основного текста;
- выделение скрытых тематических структур в новостном потоке с использованием тематического моделирования;
- построение временных рядов интенсивности тем и оценка динамики их развития;
- объединение тематических, временных и эмоциональных признаков в единый индекс тенденции;

- проведение статистической проверки устойчивости выявленных трендов.

Достижение поставленной цели требует решения ряда взаимосвязанных задач, охватывающих этапы подготовки данных, построения модели и анализа результатов.

Важным этапом разработки модели является определение критериев оценки её эффективности. Для оценки качества работы алгоритмов классификации широко используются статистические метрики, позволяющие количественно оценить точность предсказаний модели [1.11].

Критериями успешности предлагаемого решения выступают:

- достижение показателей общей точности и взвешенной F1-меры, существенно превышающих результаты базовых предобученных моделей (в частности, достижение уровня точности более 75% на целевой выборке);
- способность модели корректно идентифицировать позитивную и негативную тональность с показателями полноты (recall) выше 70%, что критически важно для корректного расчета динамики трендов;
- выделенные с помощью LDA тематические кластеры должны обладать высокой степенью логической связности и соответствовать реальным направлениям научно-технологического развития;
- выявленные на основе агрегированных данных тенденции должны подтверждаться методами статистического анализа и адекватно отражать структурные изменения в информационном пространстве.

Решение поставленных задач и достижение указанных критериев эффективности позволит разработать модель анализа тональности новостных публикаций, пригодную для исследования динамики научно-технологических тенденций в информационном пространстве.

1.3.2 Формализация требований к разрабатываемому решению

В общем виде задача анализа тональности может быть представлена как задача многоклассовой классификации текстов. Пусть задано множество текстовых документов (1.1):

$$D = \{x_1, x_2, \dots, x_N\}, \quad (1.1)$$

где x_i — текст i новости или её заголовок;

N — количество новостей.

Каждому тексту должна быть сопоставлена метка тональности из заданного множества классов (1.2):

$$y_i \in Y, \quad (1.2)$$

где $Y = \{NEGATIVE, NEUTRAL, POSITIVE\}$.

Задача модели заключается в построении отображения (1.3):

$$f: X \rightarrow Y, \quad (1.3)$$

которое позволяет для каждого текста x_i определить соответствующий класс тональности.

Входными данными системы являются текстовые материалы новостных публикаций научно-технологической тематики. Каждый элемент входного набора данных представляет собой строку текста, содержащую заголовок новости или полный текст публикации. Текст может содержать различные символы, включая буквы, цифры и знаки пунктуации.

Перед передачей текста в модель выполняется этап предварительной обработки. Затем данные используются в качестве входа модуля машинного обучения. Основу модели составляет предварительно обученная языковая

модель RuBERT. Данная модель была обучена на больших корпусах русскоязычных текстов и способна формировать контекстные представления слов. Однако для повышения эффективности анализа новостных публикаций научно-технологической тематики используется процедура дообучения модели на специализированном наборе данных.

Пусть задан обучающий набор данных (1.4):

$$D = (x_1, y_1), (x_2, y_2), \dots, (x_m, y_m), \quad (1.4)$$

где x_i — текст новостной публикации;

y_i — соответствующая метка тональности.

Процедура дообучения модели заключается в оптимизации параметров нейронной сети таким образом, чтобы минимизировать функцию потерь на обучающей выборке. В качестве функции потерь используется функция кросс-энтропии, применяемая в задачах многоклассовой классификации.

В процессе обучения модель формирует вектор вероятностей принадлежности текста к каждому из классов тональности (1.5):

$$S = (s_1, s_2, s_3), \quad (1.5)$$

где s_1, s_2, s_3 соответствуют вероятностям принадлежности текста к классам NEGATIVE, NEUTRAL и POSITIVE.

Итоговая метка тональности определяется как класс с максимальным значением вероятности.

Параллельно с анализом тональности выполняется тематическое моделирование корпуса на основе вероятностного метода Latent Dirichlet Allocation (LDA) [1.12]. Корпус представляется в формате Bag-of-Words, после чего для каждого документа вычисляется распределение вероятностей принадлежности к скрытым темам (1.6):

$$p_i = (p_{i,1}, p_{i,2}, \dots, p_{i,K}), \quad (1.6)$$

где $p_{i,K}$ — вероятность принадлежности x_i текста к K теме.

Для перехода от анализа отдельных документов к оценке дискретной динамики информационного пространства производится агрегация показателей по временным интервалам.

Для анализа тенденций должна быть реализована временная агрегация тематик. Интенсивность темы k в момент времени t определяется как (1.7):

$$V_{k,t} = \frac{1}{N_t} \sum_{d \in D_t} P_{k,d}, \quad (1.7)$$

где N_t — число публикаций за временной период;

$P_{k,d}$ — вероятность принадлежности документа теме.

Для оценки динамики изменения тематик должна рассчитываться скорость изменения тематической интенсивности (1.8):

$$G_{k,t} = \frac{V_{k,t} - V_{k,t-1}}{V_{k,t-1} + \varepsilon}, \quad (1.8)$$

где ε используется для предотвращения деления на ноль.

Дополнительно система должна учитывать эмоциональный контекст развития темы. Средняя тональность темы определяется как (1.9):

$$S_{k,t} = \frac{\sum P_{k,d} \cdot s_d}{\sum P_{k,d}}, \quad (1.9)$$

где s_d — тональность документа;

$P_{k,d}$ — вероятность принадлежности документа теме.

На основе указанных признаков должна формироваться оценка тенденции (1.10):

$$T_{k,t} = w_1 z(V_{k,t}) + w_2 z(G_{k,t}) + w_3 z(S_{k,t}) \quad (1.10)$$

где $w_1 + w_2 + w_3 = 1$;

$z(x)$ — функция стандартизации признаков.

Можно выделить нефункциональные требования к созданию модели:

- точность более 0,75 для превосходства над базовыми языковыми моделями за счет адаптации к предметной области и достижение сбалансированного качества классификации;
- интерпретируемость для формирования логически связанных тем, соответствующих реальной научно-технологической повестке;
- устойчивость к аномальным выбросам и использование формализованных алгоритмов для получения сопоставимых результатов при повторном анализе;
- производительность, чтобы работа с данными промышленного объема занимала не более 3 минут;
- расширяемость и модульная архитектура, позволяющая заменять компоненты (модели, методы агрегации) без перестройки всей системы.

Функциональные требования заключаются в следующем:

- автоматическая очистка от технического шума (HTML, символы), токенизация и нормализация текста для подготовки к машинному обучению;
- определение эмоционального контекста с учетом специфики языка и агрегацией оценок заголовка и текста;
- вероятностное распределение документов по темам, позволяющее одной публикации относиться к нескольким категориям одновременно;
- агрегация данных по периодам для расчета изменения информационного веса тем в масштабе многолетних архивов;

- формирование единого количественного показателя тренда на основе веса темы, её динамики и эмоционального фона;
- модуль пользовательского интерфейса (отображение динамики, распределения тем, сравнительных метрик качества).

Основное функциональное назначение разрабатываемого решения состоит в автоматическом анализе новостных публикаций и выявлении научно-технологических тенденций на основе эмоциональной окраски и временной динамики. Для выполнения этой функции система должна обеспечивать полный цикл обработки данных, начиная от загрузки исходных публикаций и заканчивая формированием аналитических выводов.

1.3.3 Определение ограничений и допущений

При разработке модели интеллектуального анализа тональности новостных потоков необходимо учитывать ряд ограничений и допущений, обусловленных спецификой анализируемых текстовых данных и особенностями применяемых алгоритмов обработки естественного языка.

Одним из ключевых допущений является предположение о наличии доминирующей тональности в каждом новостном тексте. В рамках разрабатываемой модели предполагается, что каждому документу может быть сопоставлена одна основная эмоциональная характеристика. В реальных условиях текст может содержать несколько оценочных элементов различной направленности, однако для формализации задачи анализа используется единый итоговый класс тональности.

Следующим важным допущением является независимость анализируемых текстов. В модели предполагается, что каждый новостной материал рассматривается как самостоятельная единица анализа. При этом взаимосвязи между публикациями, а также временная динамика появления новостей в рамках данной модели не учитываются.

Существенным ограничением является языковая специфика анализируемых данных. Разрабатываемая модель ориентирована на обработку русскоязычных текстов, поскольку используемые языковые модели обучены на корпусах русского языка. Вследствие этого при анализе текстов на других языках или смешанных языковых конструкциях может наблюдаться снижение точности классификации.

Следует также учитывать дисбаланс классов тональности, характерный для новостных потоков научно-технологической тематики. В подобных текстах преобладают нейтральные публикации, тогда как выраженные положительные или отрицательные оценки встречаются значительно реже.

Ещё одним ограничением является высокая вычислительная сложность современных моделей обработки естественного языка. Нейросетевые архитектуры, в частности трансформерные модели, требуют значительных вычислительных ресурсов. Это может ограничивать возможности их применения в условиях ограниченной вычислительной инфраструктуры.

Кроме того, следует учитывать особенности естественного языка, которые могут затруднять автоматическую интерпретацию тональности текста. К таким особенностям относятся многозначность слов, сложные синтаксические конструкции, контекстная зависимость выражений, а также использование иронии или метафорических оборотов.

Дополнительное влияние на точность классификации оказывает этап предварительной обработки текстовых данных. Ошибки или потери информации на данных этапах могут приводить к снижению качества анализа.

Ограничение тематического моделирования связано с использованием метода латентного размещения Дирихле. Алгоритм предполагает, что каждый документ представляет собой смесь нескольких скрытых тем.

Временной анализ выполняется в условиях дискретного временного пространства.

Предполагается, что внутри выбранного временного интервала изменения информационного потока являются статистически сопоставимыми. Более

короткие интервалы (месяц, неделя, день) в рамках данной работы не рассматривались, поскольку могут содержать значительное количество случайных информационных всплесков.

При расчёте индекса тенденций вводится допущение о линейной зависимости между признаками, влияющими на развитие темы. Итоговый показатель строится как взвешенная линейная комбинация интенсивности темы, её динамики и эмоционального фона.

Это означает, что вклад каждого признака рассматривается как независимый и аддитивный. Возможные нелинейные взаимодействия между признаками в текущей реализации не моделируются.

Отдельное ограничение связано с внешней валидацией результатов анализа тональности. Для сравнительного анализа использовалась система PolyAnalyst. При этом её результаты рассматривались не как абсолютная истинная разметка, а как внешний ориентир для оценки согласованности моделей. Вследствие этого метрики качества отражают относительное улучшение разработанного решения, а не абсолютную точность классификации в общем случае.

В итоге определённые ограничения и допущения задают условия функционирования разработанной модели, определяют границы интерпретации результатов и обеспечивают корректное применение предложенного подхода в задаче выявления научно-технологических тенденций на основе анализа новостных потоков.

2 АНАЛИТИЧЕСКИЙ РАЗДЕЛ

2.1 Анализ и характеристика входных данных

2.1.1 Описание источников и форматов данных

В рамках настоящего исследования особое значение имеет формирование текстового корпуса новостных публикаций, отражающего информационные процессы в научно-технологической сфере. В качестве основного источника данных были использованы материалы новостного интернет-издания Lenta.ru. Данный информационный ресурс относится к числу крупнейших российских новостных порталов и регулярно публикует материалы, посвящённые научным исследованиям, технологическим разработкам, инновациям и достижениям современной науки. Наличие отдельной тематической рубрики, посвящённой науке, позволяет сформировать специализированную выборку публикаций, относящихся к исследуемой области [2.1].

Выбор указанного источника обусловлен рядом факторов. Во-первых, новостной портал обладает значительным архивом публикаций, охватывающим длительный временной период. Во-вторых, структура сайта позволяет осуществлять автоматизированный доступ к архивам новостей по датам публикации, что упрощает процесс систематического сбора данных. В-третьих, публикации характеризуются сравнительно однородным стилем подачи информации и содержат описания научных достижений, технологических разработок и результатов исследований, что делает данный источник подходящим для анализа тональности новостных текстов.

Сбор данных осуществлялся при помощи специально разработанного программного инструмента — парсера новостных публикаций. Код парсера представлен в Приложении Б. Данный программный модуль реализован на языке

Python и предназначен для автоматизированного извлечения текстовой информации из веб-страниц новостного портала. Применение парсинга веб-страниц является распространённым методом формирования текстовых корпусов в задачах анализа данных и обработки естественного языка, поскольку позволяет получать большие объёмы текстовой информации без ручного копирования материалов.

Разработанный парсер осуществляет последовательный обход архивных страниц новостного раздела сайта. Архив новостей структурирован по датам публикации и имеет предсказуемый формат адреса страницы, включающий год, месяц и день публикации. Использование данной структуры позволяет автоматически формировать адреса страниц архива и получать список новостей, опубликованных в конкретный день.

Процесс сбора данных реализован в виде итеративного обхода временного интервала публикаций. В исследовании рассматривался период с 2006 по 2025 год. Для каждой даты формируется соответствующий адрес страницы архива новостей, после чего выполняется загрузка HTML-страницы и её последующий анализ.

На следующем этапе выполняется извлечение ссылок на отдельные новостные публикации. Для этого производится анализ HTML-разметки страницы с использованием библиотеки BeautifulSoup, предназначенной для обработки и анализа веб-документов. Из структуры страницы извлекаются гиперссылки, ведущие на отдельные новостные материалы. Для повышения корректности сбора данных используются фильтры, позволяющие отбирать только ссылки, соответствующие формату новостных публикаций [2.2, 2.3].

После получения списка ссылок на новости выполняется переход на каждую страницу публикации. На данном этапе осуществляется извлечение ключевых элементов новостного материала. Из HTML-структуры страницы извлекаются заголовок публикации и основной текст новости. Заголовок определяется на основе HTML-тега заголовка страницы, тогда как основной

текст формируется путём объединения абзацев, содержащихся в основном блоке статьи.

Основной текст публикации формируется как последовательность текстовых абзацев, объединённых в единый текстовый документ. В процессе извлечения выполняется очистка текста от лишних пробелов и служебных символов.

Сформированные данные сохраняются в структурированном формате JSON. Использование данного формата позволяет хранить текстовую информацию в виде набора объектов, каждый из которых соответствует отдельной новостной публикации. Формат JSON широко применяется в системах обработки данных благодаря своей гибкости, удобству сериализации и совместимости с большинством языков программирования и библиотек анализа данных [2.4].

Структура набора данных представлена в Таблице 2.1.

Таблица 2.1 — Структура данных JSON

Название признака	Описание	Тип данных
id	уникальный идентификатор записи	Целочисленный
date	дата публикации новости	Дата
year	Год публикации новости	Целочисленный
month	Месяц публикации новости	Целочисленный
day	День публикации новости	Целочисленный
title	Заголовок новости	Текстовый
url	Ссылка на оригинальную страницу новости	Текстовый
text	Основной текст новостного материала	Текстовый

Подобная структура данных обеспечивает удобство последующей обработки информации с использованием инструментов анализа данных и библиотек машинного обучения. В частности, данные могут быть легко импортированы в табличные структуры библиотек анализа данных, что позволяет выполнять дальнейшую обработку, включая очистку текстов, анализ распределений и подготовку данных для обучения моделей обработки естественного языка.

Сформированный корпус новостных публикаций представляет собой специализированный текстовый набор данных, отражающий информационное пространство научно-технологической тематики. Использование новостных материалов позволяет анализировать информационные процессы, происходящие в научной сфере, а также исследовать эмоциональную окраску сообщений, связанных с научными открытиями, технологическими разработками и инновационными проектами.

Полученный набор данных служит основой для дальнейших этапов исследования, включающих предобработку текстов, анализ характеристик данных и обучение модели интеллектуального анализа тональности новостных публикаций.

2.1.2 Методы предобработки и очистки данных

После формирования исходного корпуса новостных публикаций следующим этапом исследования является подготовка данных к дальнейшему анализу и обучению модели интеллектуального анализа тональности. Текстовые данные, полученные в результате автоматизированного парсинга веб-страниц, как правило, содержат различные шумовые элементы, связанные с особенностями HTML-разметки, форматирования текста и структурой интернет-страниц. В связи с этим требуется выполнение комплекса процедур предобработки и очистки данных.

Предобработка текстовой информации представляет собой важный этап обработки естественного языка, позволяющий привести текстовые данные к единому формату и устранить элементы, которые могут негативно повлиять на качество обучения модели. В рамках настоящего исследования предобработка данных выполнялась в несколько последовательных этапов.

Первым этапом обработки данных являлась фильтрация некорректных или неполных записей. В процессе парсинга отдельных веб-страниц возможно

возникновение ситуаций, при которых текст новости извлекается не полностью либо отсутствует вовсе. Подобные случаи могут возникать из-за изменений структуры веб-страницы, ограничений доступа к странице или временных сетевых ошибок. В разработанном алгоритме такие ситуации обрабатываются автоматически: если основной текст новости не извлекается из HTML-структуры страницы, соответствующая запись исключается из итогового набора данных. Подобная проверка реализована на этапе извлечения текста публикации и позволяет сформировать набор данных, содержащий только полноценные новостные материалы.

Следующим этапом является извлечение текстовой информации из HTML-разметки страницы. Веб-страницы новостных публикаций содержат значительное количество служебных элементов: HTML-теги, элементы интерфейса сайта, рекламные блоки и другие вспомогательные компоненты. Для выделения содержательного текста используется анализ структуры HTML-документа. В рамках данного исследования применялась библиотека BeautifulSoup, предназначенная для обработки и анализа HTML-документов. С её помощью осуществляется поиск текстовых блоков, соответствующих основному содержанию статьи, после чего из этих блоков извлекаются отдельные абзацы текста.

Извлечённые абзацы объединяются в единый текстовый документ, который представляет полный текст новостной публикации. На данном этапе также выполняется удаление пустых строк и абзацев, не содержащих текстовой информации. Подобная процедура позволяет устранить элементы форматирования и привести текст к более компактному и структурированному виду.

Важным этапом очистки данных является устранение дублирующихся записей. В процессе извлечения ссылок на новостные материалы с архивных страниц могут встречаться повторяющиеся гиперссылки на одни и те же публикации. Для предотвращения появления дубликатов в наборе данных выполняется проверка уникальности ссылок. Список ссылок на новости

преобразуется в структуру данных, содержащую только уникальные элементы, что исключает повторную обработку одной и той же публикации.

Дополнительно в процессе формирования корпуса выполняется нормализация текстовой информации. Нормализация включает удаление лишних пробелов, приведение текста к единому формату и очистку строк от служебных символов. Подобная обработка позволяет устранить артефакты форматирования, возникающие при извлечении текста из HTML-разметки.

В процессе предобработки также осуществляется структурирование данных. Каждая новостная публикация сохраняется в виде отдельного объекта, содержащего основные атрибуты записи. К таким атрибутам относятся идентификатор записи, дата публикации, заголовок новости, ссылка на оригинальный источник и основной текст статьи. Формирование структурированных записей позволяет обеспечить удобство дальнейшей обработки данных с использованием инструментов анализа данных и машинного обучения.

Для повышения устойчивости алгоритма сбора данных в процессе парсинга используются дополнительные механизмы контроля ошибок. При загрузке веб-страниц могут возникать сетевые ошибки, связанные с временной недоступностью ресурса или ограничениями на количество запросов. В подобных случаях применяется обработка исключений, позволяющая корректно пропускать проблемные страницы и продолжать процесс сбора данных. Также в алгоритме предусмотрены временные задержки между последовательными запросами к серверу. Наличие таких задержек позволяет снизить нагрузку на веб-ресурс и обеспечить более стабильную работу парсера.

В результате выполнения описанных процедур формируется очищенный и структурированный набор текстовых данных, содержащий новостные публикации научно-технологической тематики. Подготовленный корпус текстов характеризуется отсутствием дубликатов, корректной структурой записей и выделенным содержательным текстом новостных материалов. Код

предобработки данных представлен в Приложении Б. Результат предобработки представлен на Рисунке 2.1.

```
--- Новость 1 ---  
Дата: 2006-01-03  
Заголовок: Создатель iPod стал командором Ордена Британской Империи  
Фрагмент текста: Джонатан Айви (Jonathan Ive), создатель культового цифрового плеера iPod, в Новый год получил звание командора Ордена Британской Империи. Дизайнер американской компании Apple, сообщает BBC News, отмечен в новогоднем списке почета королевы Елизаветы II. Титул, как указывается в документе, является пр ...  
  
--- Новость 2 ---  
Дата: 2006-01-04  
Заголовок: Аварии шаттла Columbia пережили черви  
Фрагмент текста: На борту шаттла Columbia находились подопытные животные, которым удалось выжить в результате аварии, сообщают эксперты NASA. Спустя два года после нее судьбе червей Caenorhabditis elegans посвятили статью в журнале Astrobiology. Ученые обнаружили живых червей в четырех из пяти герметичных боксов, ко ...  
  
--- Новость 3 ---  
Дата: 2006-01-04  
Заголовок: Киты потеряли общий язык  
Фрагмент текста: Киты из разных областей океана могут не понять друга друга, считают американские биологи. Подслушать "беседы" морских млекопитающих им позволили приборы, предназначенные для мониторинга землетрясений. Киты обмениваются сообщениями при помощи обычного звука, однако исследования показали, что разные ж ...
```

Рисунок 2.1 — Пример первых строк предобработанных новостей

Полученный набор данных используется на последующих этапах исследования для проведения разведочного анализа данных, оценки распределения классов тональности и обучения модели интеллектуального анализа тональности новостных потоков.

2.1.3 Оценка качества и репрезентативности данных

После выполнения процедур сбора и предварительной обработки новостных публикаций была проведена оценка качества и репрезентативности сформированного набора данных. Данный этап является важной частью разработки систем интеллектуального анализа текстовой информации, поскольку характеристики обучающего корпуса оказывают непосредственное влияние на качество обучения моделей обработки естественного языка и достоверность получаемых результатов.

Под качеством данных в рамках настоящего исследования понимается совокупность характеристик, отражающих корректность, полноту и пригодность текстового корпуса для решения задачи анализа тональности новостных публикаций. Репрезентативность данных, в свою очередь, характеризует степень

соответствия сформированного корпуса реальному информационному пространству научно-технологических новостей.

В результате работы разработанного парсера был сформирован корпус новостных публикаций научно-технологической тематики, содержащий 94 444 новостных материала. Результат представлен на Рисунке 2.2.

Размер датасета: (94444, 8)						
	id	date	year	month	day	\
0	1	2006-01-03	2006	1	3	
1	2	2006-01-04	2006	1	4	
2	3	2006-01-04	2006	1	4	
3	4	2006-01-05	2006	1	5	
4	5	2006-01-06	2006	1	6	
						title \
0						Создатель iPod стал командором Ордена Британск...
1						Аварию шаттла Columbia пережили черви
2						Киты потеряли общий язык
3						"Рональд Рейган" вышел на первое задание
4						Китайцы тестируют пусковую установку лунного м...
						url \
0						https://lenta.ru/news/2006/01/03/apple/
1						https://lenta.ru/news/2006/01/04/shuttle/
2						https://lenta.ru/news/2006/01/04/whale/
3						https://lenta.ru/news/2006/01/05/reagan/
4						https://lenta.ru/news/2006/01/06/lunar/
						text
0						Джонатан Айви (Jonathan Ive), создатель культо...
1						На борту шаттла Columbia находились подопытные...
2						Киты из разных областей океана могут не понять...
3						Новейший атомный авианосец "Рональд Рейган" от...
4						Китай начал подготовку к запуску искусственног...

Рисунок 2.2 — Пример первых строк новостного корпуса

Каждый элемент набора данных включает дату публикации, заголовок, ссылку на источник и основной текст статьи. Наличие указанных атрибутов обеспечивает возможность дальнейшей автоматизированной обработки данных и использования корпуса в задачах анализа текстовой информации.

Одним из важных критериев качества текстового корпуса является полнота извлечения текстового содержимого новостных публикаций. В процессе формирования набора данных реализована автоматическая проверка наличия основного текста статьи. В случаях, когда извлечение текста не удавалось выполнить корректно, соответствующая запись исключалась из итогового корпуса данных. Такой подход позволил сформировать набор данных, содержащий только полноценные новостные публикации, пригодные для последующего анализа.

Дополнительным критерием качества данных является структурная целостность набора. Каждая запись корпуса имеет единую структуру и содержит следующие поля: уникальный идентификатор новости, дату публикации, заголовок, ссылку на оригинальную страницу и основной текст статьи. Наличие стандартизированной структуры данных обеспечивает возможность последующей интеграции корпуса с инструментами анализа данных и библиотеками машинного обучения.

Для оценки характеристик текстового корпуса был проведён разведочный анализ данных, включающий анализ статистических показателей длины новостных публикаций. Данный анализ позволяет выявить возможные аномалии в структуре текстов, например слишком короткие или, наоборот, чрезмерно длинные сообщения, которые могут оказывать влияние на процесс обучения моделей обработки естественного языка.

В результате проведённого анализа были получены следующие статистические характеристики текстового корпуса:

- общее количество новостных публикаций — 94 444;
- средняя длина текста новости — 189,66 слова;
- медианная длина текста — 179 слов;
- максимальная длина текста — 1069 слов;
- минимальная длина текста — 6 слов.

Полученные показатели свидетельствуют о том, что большинство новостных публикаций имеют сопоставимую длину текста и относятся к категории коротких или средних информационных сообщений. Разница между средним и медианным значениями длины текста является незначительной, что указывает на относительно равномерное распределение длины новостных материалов в корпусе.

Минимальное значение длины текста, равное шести словам, связано с наличием коротких новостных сообщений. Максимальная длина текста превышает тысячу слов из-за присутствия в новостном потоке более

развёрнутых аналитических публикаций. Однако такие случаи встречаются редко и не оказывают существенного влияния на общую структуру корпуса.

Дополнительно в рамках разведочного анализа была построена графическая визуализация распределения длины текстов, которая представлена на Рисунке 2.3.




Рисунок 2.3 — Распределение длины новостей

На Рисунке 2.4 представлена динамика количества новостных публикаций. Использование визуализации данных позволяет более наглядно оценить характеристики текстового корпуса и выявить возможные закономерности в структуре новостных потоков.




Рисунок 2.4 — Распределение длины новостей

Полученные результаты анализа позволяют сделать вывод о том, что сформированный корпус новостных публикаций обладает достаточным объёмом и разнообразием текстовых материалов для решения задачи интеллектуального анализа тональности. Значительное количество новостных сообщений обеспечивает репрезентативность данных и позволяет обучать модели обработки естественного языка на достаточно большом наборе текстов.

Вследствие этого сформированный набор данных может рассматриваться как репрезентативный корпус научно-технологических новостей, пригодный для дальнейшего применения в задачах интеллектуального анализа текстовой информации. Полученные данные используются на последующих этапах исследования для обучения модели анализа тональности новостных публикаций и выявления научно-технологических тенденций в информационном пространстве.

2.2 Описание этапов разработки модели

2.2.1 Проектирование архитектуры решения

Разработка системы интеллектуального анализа тональности новостных потоков требует построения архитектуры, обеспечивающей последовательную обработку текстовой информации и получение результатов классификации тональности новостных публикаций. Архитектура разрабатываемого решения представляет собой совокупность взаимосвязанных компонентов, обеспечивающих сбор данных, их обработку, применение модели анализа тональности, выявления тенденций и формирование итоговых результатов.

Основной целью проектирования архитектуры является создание структурированной системы обработки текстовых данных, позволяющей автоматически анализировать новостные публикации научно-технологической

тематики определять их эмоциональную окраску, получать темы и выявлять тенденции. В рамках исследования архитектура системы построена по модульному принципу, при котором каждый компонент отвечает за выполнение отдельного этапа обработки информации. Схема взаимодействия компонентов модели представлена на Рисунке 2.5.




Рисунок 2.5 — Взаимодействие модулей модели

Взаимодействие компонентов разработанной системы организовано в виде последовательного процесса обработки новостных данных, включающего этапы сбора информации, подготовки текстов, обучения модели и последующего использования обученной модели в пользовательском интерфейсе. Архитектура решения построена по модульному принципу, что обеспечивает логическое разделение функций системы и позволяет независимо выполнять обработку данных, обучение модели, анализ и представление результатов.

На первом этапе функционирования системы осуществляется получение исходных данных. В качестве источника информации используется новостной портал Lenta.ru, а именно рубрика «Наука и технологии». Из данного источника извлекаются публикации в формате HTML-страниц, содержащие новостные материалы. Для автоматизации процесса сбора данных реализован специализированный программный модуль — парсер новостей. Данный компонент разработан на языке программирования Python с использованием библиотек requests и BeautifulSoup. Парсер выполняет последовательный обход страниц новостного архива, формирует HTTP-запросы к целевым URL и осуществляет извлечение структурированной информации из HTML-разметки

[2.5]. В результате работы модуля из каждой новости выделяются ключевые атрибуты: заголовок, полный текст публикации и дата её выхода.

Полученные данные передаются в компонент хранения, где формируется локальный датасет новостных сообщений. Данные сохраняются в формате JSON, что обеспечивает их структурированное представление и удобство последующей обработки. Такой подход позволяет накапливать исторический массив новостей и минимизировать необходимость повторного обращения к внешнему источнику данных.

Следующий этап связан с предобработкой текстовой информации. На данном уровне осуществляется очистка данных от шумовых элементов, включая служебные символы, HTML-теги и избыточные пробелы. Также выполняется нормализация текста, направленная на приведение всех новостных сообщений к единому формату представления. В рамках лингвистической обработки производится удаление стоп-слов и лемматизация, то есть приведение слов к их начальной форме. Данный этап обеспечивает повышение качества дальнейшего анализа за счёт уменьшения вариативности текстовых данных.

После завершения предобработки подготовленные тексты передаются одновременно в два аналитических блока системы. Первый блок отвечает за анализ тональности новостных сообщений. В его основе используется обученная трансформерная модель RuBERT, адаптированная для обработки русскоязычных текстов [2.6]. Модель выполняет классификацию новостей по эмоциональной окраске и относит каждое сообщение к одной из трёх категорий: позитивной, нейтральной или негативной. Результатом работы данного модуля является вероятностное распределение классов тональности для каждой новости.

Параллельно с этим функционирует модуль тематического моделирования. В данном компоненте тексты преобразуются в векторное представление с использованием подхода «мешок слов», после чего применяется алгоритм латентного размещения Дирихле (LDA — Latent Dirichlet Allocation). Данный алгоритм осуществляет автоматическое выделение скрытых тематических структур в корпусе текстов и распределяет новости по

тематическим кластерам, соответствующим различным предметным областям, таким как «космос», «медицина», «информационные технологии» и другие.

Результаты работы двух аналитических модулей поступают в компонент агрегации и анализа тенденций. На данном этапе выполняется комплексная обработка полученных данных, включающая временную агрегацию новостей по заданным интервалам, нормализацию числовых признаков и вычисление интегрального индекса тенденций. Данный индекс отражает динамику интереса к различным тематикам во времени и позволяет выявлять как растущие, так и затухающие информационные тренды в научно-технологической сфере.

Заключительным этапом функционирования системы является прикладной уровень, реализованный в виде веб-интерфейса на базе фреймворка Streamlit. Данный интерфейс обеспечивает визуализацию результатов анализа и предоставляет пользователю доступ к основным аналитическим метрикам системы. В интерфейсе отображаются графики динамики тематик, распределение новостей по категориям, а также визуальные представления рассчитанных тенденций. Таким образом, пользователь получает возможность интерактивного анализа информационного потока и наблюдения за изменением научно-технологических трендов в динамике.

В результате взаимодействия всех компонентов формируется единая программная система, реализующая полный цикл обработки новостных данных — от их автоматического сбора и структурирования до интеллектуального анализа и визуализации результатов. Такая архитектура обеспечивает масштабируемость решения и позволяет эффективно исследовать динамику развития научно-технологической повестки в информационном пространстве.

2.2.2 Описание математического аппарата реализуемого решения

Разрабатываемая модель анализа тональности новостных сообщений относится к классу моделей обработки естественного языка, основанных на

глубоких нейронных сетях и архитектуре трансформеров. Математический аппарат решения базируется на методах векторного представления текстовых данных, механизмах контекстного моделирования последовательностей и алгоритмах многоклассовой классификации. Используемый подход позволяет формализовать задачу определения тональности новостных сообщений как задачу вероятностного распределения текстовых объектов по заданным категориям [2.7].

Пусть задан корпус новостных сообщений (1.1). Каждому тексту сопоставляется метка тональности (1.2). Задача модели заключается в построении функции классификации которая отображает текстовое сообщение в один из классов тональности (1.3).

Тогда с точки зрения вероятностного моделирования задача может быть представлена как оценка условной вероятности. Модель должна определить такой класс y , для которого вероятность максимальна (2.1):

$$\hat{y} = \arg \max_{y \in Y} P(y|x), \quad (2.1)$$

где x — текст новости;

y — класс тональности.

Решение данной задачи реализуется посредством нейронной сети, обученной на размеченном корпусе новостных текстов.

Текстовые данные не могут быть непосредственно использованы в математических моделях, поэтому на первом этапе выполняется их преобразование в числовую форму. Пусть новостной текст представлен последовательностью токенов (2.2):

$$T = (t_1, t_2, \dots, t_n), \quad (2.2)$$

где t_i — отдельный токен;

n — длина текстовой последовательности.

Каждому токeну сопоставляется индекс из словаря модели (2.3):

$$t_i \rightarrow id_i, \quad (2.3)$$

где t_i — отдельный токен;
 id_i — индекс из словаря.

После этого выполняется преобразование токенов в векторные представления (эмбеддинги). Для каждого токена формируется вектор (2.4):

$$e_i \in R^d, \quad (2.4)$$

где d — размерность векторного пространства.

Тогда текстовое сообщение представляется в виде матрицы (2.5):

$$E = \begin{bmatrix} e_1 \\ e_2 \\ \dots \\ e_n \end{bmatrix}, \quad (2.5)$$

где E — эмбеддинг.

Эмбеддинги кодируют семантические свойства слов, позволяя модели учитывать сходство между различными лексическими единицами.

Поскольку архитектура трансформера не содержит рекуррентных связей, порядок слов в последовательности передаётся через механизм позиционного кодирования. Каждому токeну добавляется позиционный вектор (2.6):

$$p_i \in R^d. \quad (2.6)$$

Формирование позиционного кодирования осуществляется по Формулам (2.7) и (2.8):

$$PE(pos, 2i) = \sin\left(\frac{pos}{10000^{2i/d}}\right), \quad (2.7)$$

$$PE(pos, 2i + 1) = \cos\left(\frac{pos}{10000^{2i/d}}\right), \quad (2.8)$$

где pos — позиция токена в последовательности;

i — индекс компоненты вектора.

Итоговое представление токена вычисляется как сумма эмбединга и позиционного кодирования (2.9):

$$x_i = e_i + p_i. \quad (2.9)$$

Это позволяет модели учитывать относительное расположение слов в тексте.

Ключевым элементом архитектуры трансформера является механизм самовнимания (self-attention), который позволяет модели определять степень взаимосвязи между словами в тексте.

Для входной матрицы признаков X вычисляются три матрицы (2.10 – 2.12):

$$Q = XW_Q, \quad (2.10)$$

$$K = XW_K, \quad (2.11)$$

$$V = XW_V, \quad (2.12)$$

где Q — матрица запросов (Query);

K — матрица ключей (Key);

V — матрица значений (Value);

W_Q, W_K, W_V — обучаемые параметры модели.

После этого вычисляется матрица внимания вычисляется по Формуле (2.13):

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V, \quad (2.13)$$

где d_k — размерность вектора ключей.

Эта операция позволяет определить, какие элементы последовательности наиболее значимы при формировании контекстного представления каждого токена.

Для повышения выразительности модели используется механизм многоголового внимания (multi-head attention). Он позволяет анализировать текст одновременно в нескольких различных подпространствах признаков.

Формально многоголовое внимание определяется как (2.14):

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W_O, \quad (2.14)$$

где h — число голов внимания.

Каждая голова вычисляется как (2.15):

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V). \quad (2.15)$$

Каждая «голова» внимания выявляет различные типы зависимостей между словами, например синтаксические или семантические связи.

После слоя внимания используется позиционно-независимая нейронная сеть, состоящая из двух полносвязных слоёв (2.16):

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2, \quad (2.16)$$

где W_1, W_2 — матрицы весов;

b_1, b_2 — векторы смещений.

Функция активации ReLU обеспечивает нелинейное преобразование признаков и повышает выразительную способность модели. [2.8]

В архитектуре BERT используется специальный токен [CLS], который помещается в начало входной последовательности. После прохождения через все слои трансформера формируется вектор h_{CLS} . Этот вектор рассматривается как компактное представление всего текста.

Для решения задачи анализа тональности используется линейный классификатор, принимающий на вход вектор h_{CLS} (2.17):

$$z = Wh_{CLS} + b, \quad (2.17)$$

где W — матрицы весов классификатора;

b — вектор смещений.

Полученный вектор z преобразуется в вероятностное распределение с помощью функции softmax (2.18):

$$P(y = i|x) = \frac{e^{z_i}}{\sum_{j=1}^k e^{z_j}}, \quad (2.18)$$

где k — число классов.

Модель выбирает класс с максимальной вероятностью.

Обучение выполняется за счет минимизации кросс-энтропии (2.19):

$$L = -\sum_{i=1}^k y_i \log(p_i), \quad (2.19)$$

где y_i — истинная метка класса;

p_i — предсказанная моделью вероятность.

Функция потерь измеряет расхождение между истинным распределением классов и предсказанием модели.

Минимизация функции потерь осуществляется методом градиентного спуска. Обновление параметров модели выполняется по правилу (2.20):

$$\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t), \quad (2.20)$$

где θ — параметры модели;

η — коэффициент скорости обучения.

Для ускорения и стабилизации обучения используется модифицированный алгоритм оптимизации Adam, который учитывает адаптивную оценку первых и вторых моментов градиента.

Предобученная модель RuBERT содержит параметры, полученные на больших русскоязычных корпусах. Для адаптации модели к тематике научных новостей применяется метод fine-tuning.

Пусть обучающая выборка имеет вид (1.4). В процессе обучения минимизируется функция потерь (2.21)

$$L(\theta) = - \sum_{i=1}^m \sum_{j=1}^k y_{ij} \log P(y = j | x_i). \quad (2.21)$$

В результате оптимизации параметры модели адаптируются к специфике научно-технологических новостей. Результат работы модели представлен как вероятность принадлежности к одному из трех классов (1.5).

В результате применения описанного математического аппарата формируется нейросетевая модель, способная автоматически определять тональность новостных сообщений. Модель принимает на вход текст новости, преобразует его в векторное представление, анализирует контекстные зависимости между словами и вычисляет вероятности принадлежности текста к одному из классов тональности.

Использование трансформерной архитектуры и контекстных эмбеддингов позволяет учитывать сложные семантические структуры текста и обеспечивает высокую точность анализа новостных сообщений. Дополнительное дообучение модели на специализированном корпусе научно-технологических новостей обеспечивает её адаптацию к предметной области и повышает качество классификации тональности информационных потоков.

Для выделения скрытых тематических направлений в корпусе новостных текстов использовался метод латентного размещения Дирихле, который опирается на вероятностную модель генерации документов. В основе метода лежит представление текста в виде модели «мешка слов» (Bag-of-Words), позволяющей перейти от последовательности слов к векторному описанию документа.

После предобработки каждый документ преобразуется в вектор частот слов (2.22):

$$x_i = (c_{i1}, c_{i2}, \dots, c_{iV}), \quad (2.22)$$

где x_i — вектор документа d_i ;

c_{iv} — количество вхождений слова в документе;

V — размер словаря.

Длина документа равна сумме всех частот слов. Метод LDA предполагает существование скрытых тематик, которые объясняют наблюдаемую структуру документов. Каждый документ представляется как распределение тем (1.6). Каждая тема задаётся распределением слов, где каждая тема представляет вероятностное распределение по словарю (2.23):

$$\phi_k = (\phi_{k1}, \phi_{k2}, \dots, \phi_{kV}), \quad (2.23)$$

где ϕ_{kv} — вероятность слова в теме k .

Распределения p_i и ϕ_k задаются через распределение Дирихле (2.24, 2.25):

$$p_i \sim Dir(\alpha), \quad (2.24)$$

где α — вектор гиперпараметров, определяющий плотность распределения тем в документе.

$$\phi_k \sim Dir(\beta), \quad (2.25)$$

где β — вектор гиперпараметров, определяющий распределение слов внутри темы.

Модель описывает процесс генерации документа как последовательность вероятностных шагов. Для каждого документа d_i случайным образом определяется, какие темы и в какой степени в нём присутствуют. Далее для каждого слова из документа выполняются два шага с помощью полиномиального распределения (2.26):

$$z_{i,n} \sim Multinomial(p_i), \quad (2.26)$$

где $z_{i,n}$ — скрытая переменная, указывающая тему слова.

Для каждого слова сначала выбирается тема, к которой оно относится. Далее слово выбирается из распределения слов соответствующей темы. (2.27):

$$w_{i,n} \sim Multinomial(\phi_{z_{i,n}}), \quad (2.27)$$

где $w_{i,n}$ — выбранное слово.

С учётом всех тем вероятность появления слова w в документе определяется как (2.28):

$$P(w | d_i) = \sum_{k=1}^K p_{ik} \phi_{kw}, \quad (2.28)$$

где $P(w | d_i)$ — вероятность появления слова w в документе d_i ;

K — количество тем.

Задача обучения заключается в нахождении распределений тем в документах и распределений слов в темах. Максимизируется правдоподобие корпуса (2.29):

$$P(D | \alpha, \beta) = \prod_{i=1}^N P(d_i | \alpha, \beta). \quad (2.29)$$

Это означает, что модель подбирает такие параметры, при которых наблюдаемые документы наиболее вероятны.

После обучения модели для каждого документа определяется вероятность принадлежности к каждой теме (1.6). Далее для каждой темы определяется набор наиболее характерных слов. Полученные вероятности используются для расчёта динамики тем (1.7). Вследствие этого становится возможным выявление научно-технологических тенденций на основе изменения тематической структуры новостного потока.

2.2.3 Разработка вычислительной схемы

Вычислительная схема разрабатываемой системы предназначена для последовательной обработки новостных текстов, их преобразования в формализованное представление и последующего определения тональности с использованием нейросетевой модели обработки естественного языка. Основная задача вычислительной схемы заключается в организации последовательности вычислительных процедур, обеспечивающих преобразование исходных текстовых данных в итоговую оценку тональности.

В рамках разработанного решения вычислительная схема представляет собой последовательность взаимосвязанных этапов обработки данных, каждый из которых выполняет определённую функцию в процессе анализа новостных потоков. Входными данными системы выступают текстовые публикации научно-технологической тематики, представленные в виде новостных заголовков или полных текстов сообщений.

На Рисунке 2.6 изображена вычислительная схема.




Рисунок 2.6 — Схема вычислительного процесса анализа тенденций

На первом этапе вычислительной схемы выполняется загрузка исходных данных. Текстовые материалы могут поступать из различных источников, включая новостные агрегаторы, базы данных публикаций или подготовленные наборы данных. На данном этапе осуществляется считывание данных из файлового хранилища и их преобразование в табличный формат для дальнейшей обработки.

Следующим этапом является предварительная обработка текстов. Данный этап включает очистку текстовых данных от лишних символов, служебных элементов и шумовой информации. В процессе предобработки выполняется удаление HTML-разметки, специальных символов и повторяющихся пробелов. Дополнительно может выполняться нормализация текста, включающая приведение символов к единому регистру.

После выполнения очистки текста осуществляется этап токенизации. Токенизация представляет собой процесс разбиения текста на

последовательность токенов — минимальных смысловых единиц, используемых моделью обработки естественного языка. В рамках используемой архитектуры трансформеров применяется подсловная токенизация, позволяющая эффективно обрабатывать редкие слова и специализированную терминологию научных текстов.

На следующем этапе выполняется преобразование токенов в числовое представление. Для этого используется словарь токенов, сформированный в процессе предварительного обучения языковой модели. Каждому токену сопоставляется уникальный идентификатор, который затем используется в качестве входных данных нейронной сети. В результате текст преобразуется в последовательность числовых индексов фиксированной длины.

Далее сформированные числовые представления передаются на вход нейросетевой модели анализа тональности. В качестве базовой модели используется архитектура трансформеров, реализованная в модели RuBERT. Модель обрабатывает последовательность токенов и формирует контекстное векторное представление текста, учитывающее взаимосвязи между словами и общий смысл текста.

Полученное векторное представление передается в классификационный слой нейронной сети, который выполняет вычисление вероятностей принадлежности текста к каждому из классов тональности. На данном этапе применяется функция активации softmax, позволяющая преобразовать выходные значения нейронной сети в вероятностное распределение.

Результатом вычисления является набор вероятностей для каждого класса тональности (отрицательная, нейтральная и положительная).

После вычисления вероятностей выполняется процедура выбора итогового класса. Итоговая метка тональности определяется как класс с максимальным значением вероятности. Данный этап представляет собой финальную стадию обработки текста.

Полученная оценка тональности может использоваться для дальнейшего анализа новостных потоков. На основе совокупности результатов

классификации возможно выявление динамики изменения информационного фона в научно-технологической сфере, а также определение тенденций развития научных направлений.

Затем каждый документ представляется в виде числового вектора с использованием модели «мешка слов». Каждому уникальному слову корпуса сопоставляется компонент вектора, значение которого отражает частоту появления слова в документе. Дополнительно формируется матрица, где строки соответствуют новостям, а столбцы — словам словаря.

На основе полученной матрицы применяется алгоритм LDA, который рассматривает документ как смесь скрытых тем, а тему — как распределение слов. Вычислительно процесс можно описать как итерационную оптимизацию двух вероятностных распределений тем в документе и распределение слов в теме. Алгоритм выполняет последовательные итерации до сходимости, в ходе которых уточняется принадлежность каждого слова к определённой теме.

На выходе формируются два основных результата: тематическое распределение документов (доля каждой темы в конкретной новости) и тематический профиль корпуса (набор ключевых слов, описывающих каждую тему). Каждой новости сопоставляется доминирующая тема, определяемая по максимальному значению вероятности принадлежности.

Новости группируются по временным интервалам. Для каждой группы рассчитывается количество новостей по каждой теме и доля темы в общем потоке за период. Это позволяет перейти от дискретных текстов к временным рядам тематической активности. Для обеспечения сопоставимости данных выполняется нормализация признаков. Частоты тем приводятся к относительным значениям и устраняется влияние различий в объёмах новостного потока между периодами.

Ключевым вычислительным элементом является формирование индекса тенденций, который отражает динамику интереса к каждой тематике. Индекс рассчитывается как интегральная характеристика, включающая частоту появления темы в периоде, изменение частоты между соседними временными

интервалами и нормированную долю темы в общем потоке. Фактически выполняется переход от статического распределения тем к их динамическому представлению во времени. На основе временного ряда индекса выполняется оценка направления изменения (рост интереса, спад интереса, стабильное состояние). Это позволяет классифицировать тематические направления по характеру их эволюции в информационном пространстве.

Представленная вычислительная схема отражает полный цикл обработки текстовых данных в разработанной системе анализа тональности. Она демонстрирует последовательность вычислительных процедур и взаимосвязь между этапами обработки информации.

Использование подобной схемы позволяет формализовать процесс анализа новостных текстов и обеспечить воспроизводимость результатов при обработке различных наборов данных. Вследствие этого становится возможным применять разработанную модель для анализа больших потоков новостной информации и выявления научно-технологических тенденций в информационном пространстве.

2.3 Обоснование выбора инструментальных средств разработки

2.3.1 Сравнительный анализ и критерии выбора программных инструментов

Разработка модели интеллектуального анализа тональности новостных потоков требует применения специализированных программных инструментов, обеспечивающих эффективную обработку текстовых данных, обучение моделей машинного обучения и последующий анализ результатов. В рамках проектирования решения был проведён сравнительный анализ различных

языков программирования, библиотек обработки данных и сред разработки, применяемых в задачах анализа текстовой информации и машинного обучения.

Одним из ключевых этапов выбора инструментальных средств является определение языка программирования, который будет использоваться для реализации системы. Наиболее распространёнными языками программирования в области анализа данных и обработки естественного языка являются Python, R и Java.

Язык программирования Python в настоящее время является одним из наиболее популярных инструментов в области анализа данных и разработки систем машинного обучения. Его широкое распространение связано с наличием большого количества специализированных библиотек, ориентированных на обработку текстов, построение моделей машинного обучения и работу с нейронными сетями. Кроме того, Python обладает простой и понятной синтаксической структурой, что облегчает разработку и поддержку программных решений. Важным преимуществом Python является активное развитие экосистемы библиотек для обработки естественного языка и глубокого обучения, включая библиотеки PyTorch, TensorFlow и Transformers.

Язык программирования R также широко используется в задачах анализа данных и статистического моделирования. Основным преимуществом данного языка является развитый набор статистических методов и инструментов визуализации данных. Однако при решении задач обработки естественного языка и построения нейросетевых моделей возможности R оказываются более ограниченными по сравнению с Python. Кроме того, интеграция современных архитектур глубокого обучения в R реализована менее полно.

Язык программирования Java широко применяется при разработке корпоративных информационных систем и крупных программных комплексов. Его преимуществами являются высокая производительность и развитые средства объектно-ориентированного программирования. Однако в области анализа текстовых данных и машинного обучения Java используется

значительно реже, поскольку большинство современных библиотек обработки естественного языка ориентированы на экосистему Python.

Сравнение основных характеристик рассматриваемых языков программирования представлено в Таблице 2.2.

Таблица 2.2 — Сравнение языков программирования для задач анализа текстовых данных

Критерий	Python	R	Java
Поддержка машинного обучения	высокая	средняя	средняя
Библиотеки обработки естественного языка	развитые	ограниченные	ограниченные
Поддержка нейросетевых моделей	высокая	средняя	средняя
Удобство разработки	высокое	среднее	среднее
Популярность в Data Science	очень высокая	высокая	средняя

Проведённый анализ показывает, что язык программирования Python обладает наиболее широкими возможностями для разработки систем интеллектуального анализа текстовых данных. Вследствие этого данный язык был выбран в качестве основного инструмента реализации разработанной модели.

Следующим важным аспектом является выбор библиотек машинного обучения и обработки текстов. В рамках анализа были рассмотрены несколько популярных библиотек, используемых при разработке моделей обработки естественного языка.

Библиотека `scikit-learn` представляет собой один из наиболее известных инструментов для реализации алгоритмов машинного обучения. Она включает широкий набор методов классификации, кластеризации и регрессии. Однако возможности `scikit-learn` в области глубокого обучения ограничены, поскольку библиотека ориентирована преимущественно на классические алгоритмы машинного обучения.

Фреймворк `TensorFlow` является одной из наиболее распространённых платформ для разработки нейронных сетей. Данный инструмент предоставляет мощные средства для создания и обучения моделей глубокого обучения, включая распределённые вычисления и поддержку графических процессоров.

Несмотря на высокую функциональность, использование TensorFlow может быть более сложным для реализации некоторых задач обработки естественного языка [2.9].

Фреймворк PyTorch представляет собой современную библиотеку для разработки нейронных сетей, активно используемую в научных исследованиях и разработке моделей машинного обучения. Одним из ключевых преимуществ PyTorch является гибкость построения вычислительных графов и удобство разработки нейросетевых архитектур. Кроме того, данный фреймворк широко используется при разработке современных моделей обработки естественного языка [2.10].

Для реализации трансформерных моделей обработки текста широко применяется библиотека Transformers, разработанная компанией Hugging Face [2.11]. Данная библиотека предоставляет готовые реализации современных языковых моделей, включая BERT, RoBERTa, GPT и другие архитектуры глубокого обучения. Использование данной библиотеки значительно упрощает процесс применения предварительно обученных языковых моделей и их дообучения на специализированных наборах данных.

Сравнение рассматриваемых библиотек представлено в Таблице 2.3.

Таблица 2.3 — Сравнение библиотек машинного обучения

Библиотека	Основное назначение	Поддержка нейронных сетей	Поддержка NLP
scikit-learn	классическое машинное обучение	ограниченная	ограниченная
TensorFlow	глубокое обучение	высокая	высокая
PyTorch	глубокое обучение	высокая	высокая
Transformers	обработка естественного языка	высокая	специализированная

Проведённый анализ показывает, что наиболее эффективным решением для реализации модели анализа тональности является использование библиотеки PyTorch совместно с библиотекой Transformers. Такое сочетание позволяет использовать современные архитектуры трансформеров и обеспечивает высокую гибкость разработки нейросетевых моделей.

Сравнительный анализ моделей для анализа тональности русскоязычных текстов представлен в Таблице 2.4.

Таблица 2.4 — Сравнение модели RuBERT аналогами

Критерий	RuBERT (выбранная модель)	mBERT (мультязычный BERT)	FastText/ Word2Vec	Лексиконные методы
Языковая специализация	Специализированная модель для русского языка	Поддержка 104 языков, включая русский	Зависит от обучающего корпуса	Требует русскоязычного словаря
Качество на русском языке	Высокое (обучена на русском корпусе)	Среднее (разделение ресурсов между языками)	Низко-среднее	Низкое
Работа с профессиональной терминологией	Хорошая	Удовлетворительная	Ограниченная	Очень слабая
Вычислительная сложность	Средняя	Высокая	Низкая	Минимальная
Учёт контекста	Двунаправленный контекст	Двунаправленный контекст	Учёт локального контекста	Отсутствует

Для тематического моделирования рассматривались Latent Dirichlet Allocation (LDA), Non-negative Matrix Factorization (NMF) и BERTopic.

LDA является классическим вероятностным методом тематического моделирования, хорошо интерпретируемым и широко используемым в задачах анализа текстов. Он не требует сложных вычислительных ресурсов и хорошо работает на средних по объему корпусах [2.12].

NMF обеспечивает линейно-алгебраический подход к выделению тем, однако в некоторых случаях уступает LDA по устойчивости результатов.

BERTopic основан на современных языковых эмбедингах и обеспечивает более высокое качество тематического разбиения, однако требует значительных вычислительных ресурсов и сложнее в настройке.

С учетом целей исследования, связанных с интерпретируемостью результатов и устойчивостью модели, был выбран алгоритм LDA как наиболее сбалансированный по критериям простоты реализации и качества тематического разбиения.

Помимо выбора языков программирования и библиотек важную роль играет выбор среды разработки. Среди наиболее распространённых инструментов разработки можно выделить интегрированные среды разработки Visual Studio Code, PyCharm и интерактивную среду Jupyter Notebook.

Среда Jupyter Notebook широко применяется в задачах анализа данных и машинного обучения благодаря возможности интерактивного выполнения кода и визуализации результатов анализа. Однако при разработке крупных программных систем использование данной среды может быть менее удобным.

Среда PyCharm предоставляет развитые средства разработки программных проектов на языке Python, включая инструменты отладки, автоматического анализа кода и управления зависимостями. Данная среда разработки активно используется при создании крупных программных решений.

Редактор Visual Studio Code является универсальной средой разработки, поддерживающей множество языков программирования и обладающей гибкой системой расширений. Он обеспечивает удобную интеграцию с инструментами машинного обучения и системами управления версиями.

Проведённый сравнительный анализ инструментальных средств разработки позволяет определить оптимальный набор технологий для реализации системы анализа тональности новостных потоков. В качестве основного языка программирования выбран Python, а в качестве основных библиотек машинного обучения используются PyTorch и Transformers. Данный набор инструментов обеспечивает высокую гибкость разработки, поддержку современных методов обработки естественного языка и возможность эффективного обучения нейросетевых моделей.

2.3.2 Описание выбранной среды разработки и требований к инфраструктуре

Для реализации модели интеллектуального анализа тональности новостных потоков была сформирована программная среда разработки, обеспечивающая обработку текстовых данных, обучение нейросетевых моделей и демонстрацию результатов анализа. При выборе инструментальных средств учитывались такие критерии, как поддержка современных библиотек машинного обучения, удобство разработки, возможность работы с русскоязычными текстами и доступность средств визуализации результатов.

В качестве основного языка программирования используется язык Python, который является одним из наиболее распространённых инструментов в области анализа данных, машинного обучения и обработки естественного языка. Широкое распространение Python обусловлено развитой экосистемой библиотек, высокой скоростью разработки и активной поддержкой научного и инженерного сообщества. Использование данного языка позволяет эффективно реализовать как этапы обработки данных, так и алгоритмы обучения моделей.

Для работы с табличными данными и подготовки обучающих выборок используется библиотека Pandas, которая предоставляет удобные инструменты для загрузки, структурирования и обработки данных. С её помощью выполняются операции чтения данных из файлов, фильтрации записей, преобразования форматов данных и формирования обучающих наборов.

Численные вычисления и операции над многомерными массивами выполняются с использованием библиотеки NumPy. Данная библиотека является базовым инструментом для научных вычислений в Python и используется во многих библиотеках машинного обучения.

В качестве основного фреймворка для реализации нейросетевой модели используется библиотека PyTorch. Данный инструмент предоставляет средства для построения и обучения нейронных сетей, а также поддерживает выполнение вычислений на графических процессорах. PyTorch широко применяется в

научных исследованиях и разработке систем искусственного интеллекта благодаря гибкости архитектуры и удобству реализации сложных моделей.

Для работы с современными архитектурами обработки естественного языка используется библиотека Transformers, разработанная компанией Hugging Face. Данная библиотека предоставляет готовые реализации трансформерных моделей, включая архитектуру BERT. В рамках настоящей работы используется русскоязычная языковая модель RuBERT, предназначенная для анализа текстов на русском языке. Применение данной модели позволяет учитывать контекстные связи между словами и повышает точность определения тональности текстовых данных.

Для оценки качества работы модели используются инструменты библиотеки scikit-learn, которая предоставляет набор методов для вычисления метрик классификации.

Для выявления скрытых тематических структур в новостном корпусе применяется алгоритм вероятностного тематического моделирования латентное размещение Дирихле (LDA). Программная реализация данного метода выполнена с использованием библиотеки gensim, предоставляющей высокооптимизированные алгоритмы обучения и инференса вероятностных моделей на больших текстовых корпусах. Библиотека позволяет автоматизировать формирование словаря, преобразование текстов в мешок слов и обучение LDA-модели с заданным числом тематик. Результаты тематического моделирования в виде распределений вероятностей принадлежности документов к темам передаются в модуль статистической агрегации для расчёта временной динамики и построения интегрального индекса научно-технологических тенденций. Тесная интеграция gensim с библиотеками pandas и numpy обеспечивает эффективную обработку данных и минимизирует затраты вычислительных ресурсов на этапе формирования тематических признаков.

Для проведения экспериментов с данными и тестирования моделей используется интерактивная среда Jupyter Notebook, позволяющая выполнять код поэтапно и анализировать результаты вычислений.

Для демонстрации работы разработанной модели был реализован простой веб-интерфейс с использованием фреймворка Streamlit. Данный инструмент предназначен для быстрого создания веб-приложений для анализа данных и моделей машинного обучения.

Разработка и обучение модели требуют соответствующих вычислительных ресурсов. В рамках работы используется вычислительная инфраструктура персонального компьютера со следующими характеристиками:

- центральный процессор архитектуры x86-64;
- оперативная память объёмом не менее 8-16 ГБ;
- графический процессор с поддержкой CUDA (при наличии) для ускорения обучения нейросетевых моделей;
- операционная система семейства Windows или Linux;
- установленная среда Python версии 3.9 или выше.

Использование графического процессора позволяет существенно сократить время обучения трансформерных моделей, поскольку подобные архитектуры требуют значительных вычислительных ресурсов. При отсутствии графического ускорителя обучение модели также возможно на центральном процессоре, однако время вычислений при этом увеличивается.

Хранение исходных данных и результатов экспериментов осуществляется в файловой системе в формате CSV, что обеспечивает удобство загрузки данных в среду анализа. Управление версиями программного кода осуществляется с использованием системы контроля версий Git, позволяющей отслеживать изменения в процессе разработки и поддерживать воспроизводимость результатов.

Применение выбранных инструментальных средств и вычислительной инфраструктуры обеспечивает возможность эффективной реализации модели анализа тональности новостных потоков, проведения экспериментов с различными наборами данных и демонстрации результатов работы модели с помощью веб-интерфейса.

3 ТЕХНОЛОГИЧЕСКИЙ РАЗДЕЛ

3.1 Описание реализации модели

3.1.1 Описание хода реализации

Реализация модели интеллектуального анализа тональности научно-технологических новостей была построена как последовательный вычислительный пайплайн, включающий отбор обучающих данных, балансировку классов, токенизацию текстов, дообучение трансформерной модели и оценку качества на валидационной выборке. В качестве базовой архитектуры использовалась предварительно обученная русскоязычная модель blanchefort/rubert-base-cased-sentiment, ориентированная на задачу анализа тональности текстов на русском языке [3.1].

Первым этапом реализации стало формирование обучающей выборки на основе отфильтрованных новостей. Для повышения качества обучающих данных был применён порог по уверенности предсказания базовой модели в 0,83. Такое ограничение позволило оставить в корпусе только те тексты, для которых исходная модель демонстрировала достаточно высокую степень уверенности в классе. После фильтрации в выборке остались тексты трёх классов тональности, однако их распределение оказалось неравномерным: положительных примеров было значительно больше, чем нейтральных и отрицательных. На этом этапе распределение классов выглядело следующим образом: POSITIVE — 2638, NEUTRAL — 793, NEGATIVE — 339. Подобный дисбаланс является типичной проблемой для научно-технологических текстов, поскольку такие публикации чаще всего имеют нейтральную оценку, тогда как отрицательная и положительная тональность встречается значительно реже.

Для устранения дисбаланса была выполнена балансировка обучающей выборки методом `oversampling`. Из исходной тренировочной части данных были выделены отдельные подмножества по каждому классу: нейтральные, положительные и отрицательные новости. Затем для каждого класса было выбрано одинаковое число примеров — 2000. Недостающие записи для малочисленных классов были получены с повторением случайной выборки [3.2]. Такой подход позволил сформировать сбалансированный набор обучающих данных и снизить риск смещения модели в сторону наиболее представленного класса. После объединения классов итоговая обучающая выборка была приведена к единому индексу, что обеспечило корректную дальнейшую обработку.

Следующим этапом стала подготовка данных к обучению модели. На этом шаге была определена схема соответствия текстовых меток числовым индексам. Для этого использовались словари `label2id` и `id2label`, полученные из конфигурации базовой модели. Такой подход обеспечивает согласованность между исходной моделью и дообучаемой версией, а также исключает расхождения в интерпретации классов тональности. В рамках подготовки данных каждая запись получила числовую метку класса, необходимую для обучения классификатора.

После этого была выполнена токенизация текстов. Для преобразования входных новостных сообщений использовался токенизатор, соответствующий модели `blanchefort/rubert-base-cased-sentiment`. Токенизация выполнялась с использованием максимальной длины последовательности 512 токенов. Выбор этого значения обусловлен тем, что тексты новостей могут быть достаточно длинными, и ограничение в 512 токенов позволяет сохранить основную смысловую часть статьи. Токенизатор преобразует текст в набор числовых индексов, который включает `input_ids` и `attention_mask`. Первый массив содержит идентификаторы токенов, второй — маску внимания, указывающую модели, какие элементы последовательности являются значимыми, а какие представляют

собой паддинг. Пример работы токенизатора, встроенного в RuBERT, представлен на Рисунке 3.1.

Рисунок 3.1 — Пример токенизации входного текста с использованием модели RuBERT

Для дообучения была использована модель `AutoModelForSequenceClassification`, инициализированная на основе `blanchefort/rubert-base-cased-sentiment`. При создании модели были явно переданы количество классов `num_labels = 3`, а также словари соответствия меток. Это обеспечивает корректную настройку выходного слоя классификатора под трёхклассовую задачу анализа тональности.

параметры обучения были заданы следующим образом: размер обучающего батча 16, размер валидационного батча 16, количество эпох 3. В качестве стратегии валидации была выбрана проверка качества после каждой эпохи обучения, а сохранение модели также выполнялось по завершении каждой эпохи. Дополнительно использовалась опция автоматической загрузки лучшей версии модели по результатам валидации.

Для оценки качества обучения была реализована функция `compute_metrics`, вычисляющая две ключевые метрики — accuracy и macro F1-score. Accuracy отражает долю правильно классифицированных текстов, а macro F1-score позволяет более объективно оценить качество работы модели на всех классах, особенно в условиях дисбаланса. Использование macro F1-score особенно важно в данной задаче, поскольку оно позволяет учитывать качество распознавания редких классов наравне с более частотными.

В процессе обучения модель проходила три эпохи. На первой эпохе было зафиксировано значение training loss 0,154, validation loss 0,046, accuracy 0,975 и macro F1 0,654. На второй эпохе метрики составили 0,025, 0,027, 0,995 и 0,656 соответственно. На третьей эпохе значения были следующими: training loss 0,033, validation loss 0,064, accuracy 0,990, macro F1 0,648. Полученные результаты показывают, что модель уверенно обучается на сформированном корпусе и демонстрирует высокую точность классификации на валидационной выборке.

Следует отметить, что столь высокое значение accuracy объясняется сбалансированной структурой обучающих данных и особенностями валидационного корпуса. Macro F1 при этом остаётся более информативной метрикой, поскольку отражает качество распознавания всех трёх классов тональности. Полученные значения подтверждают, что выбранная схема обучения оказалась работоспособной, а модель способна адаптироваться к тематике научно-технологических новостей.

После завершения обучения модель и токенизатор были сохранены для последующего использования в задачах инференса и интеграции в

пользовательский интерфейс [3.4]. Это позволило перейти к этапу практического применения модели для анализа новостных заголовков и полных текстов, а также к оценке её эффективности на независимой тестовой выборке. Полученная реализация стала основой для дальнейшего анализа результатов и сравнения с исходной моделью.

После анализа тональности был реализован модуль тематического моделирования. Для построения тематических кластеров использовались библиотеки `gensim` и `scikit-learn`. На этапе векторизации применялся `CountVectorizer` со следующими параметрами: `max_features = 5000`, `min_df = 5`, `max_df = 0,7`, `ngram_range = (1,2)`. Это позволило удалить редкие и слишком частотные слова, а также учитывать биграммы.

Тематическая модель обучалась с помощью `gensim.models.LdaModel()` с подбором количества тем от 4 до 10.

Для определения оптимального числа тем рассчитывался показатель `semantic coherence` с использованием класса `CoherenceModel`. После серии запусков максимальная устойчивость метрики была получена при 8. После этого итоговая модель переобучалась с фиксированным значением `num_topics = 8`.

Для каждого документа формировалось вероятностное распределение по темам. Далее был реализован модуль выявления тенденций.

Агрегация выполнялась средствами библиотеки `pandas` с группировкой по временным периодам `groupby(["year", "topic"])`.

Для каждой темы вычислялась интенсивность присутствия в потоке (1.7). Далее рассчитывалась относительная динамика темы (1.8). Для оценки эмоционального фона темы использовалось взвешенное усреднение (1.9). Перед объединением признаков выполнялась стандартизация через `StandardScaler()` из `scikit-learn`. После нормализации рассчитывался итоговый индекс тенденций (1.10). Весовые коэффициенты были выбраны равными. Для прогнозирования динамики тематик использовалась библиотека `statsmodels` и модель экспоненциального сглаживания `ExponentialSmoothing()`.

3.1.2 Реализация интерфейсов и взаимодействия компонентов

Реализация программной части системы интеллектуального анализа тональности новостных потоков была выполнена в среде Jupyter Notebook, что обеспечило удобство поэтапной разработки, тестирования и визуализации промежуточных результатов. В рамках выбранного подхода система не была декомпозирована на отдельные программные модули, однако логически её функциональность разделена на несколько взаимосвязанных этапов обработки данных, реализованных последовательно в едином вычислительном окружении.

Основной задачей данного этапа являлось объединение ранее разработанных модулей в единую систему, способную выполнять полный цикл анализа текстовой информации — от ввода текста до получения результата классификации.

Программная реализация системы, представленная в Приложении Б, включает несколько ключевых компонентов: модуль загрузки и хранения модели, модуль предобработки текста, модуль предсказания, а также пользовательский интерфейс, реализованный с использованием веб-фреймворка Streamlit. Каждый из компонентов выполняет строго определённую функцию, а их взаимодействие организовано в виде последовательного конвейера обработки данных.

Первым компонентом системы является модуль загрузки модели. На этапе инициализации приложения осуществляется загрузка дообученной трансформерной модели и соответствующего токенизатора из локального хранилища. Использование заранее сохранённой модели позволяет избежать повторного обучения и значительно ускоряет процесс запуска системы. Модель загружается в оперативную память и переводится в режим инференса, что обеспечивает её готовность к обработке входных данных.

Следующим элементом является модуль предобработки текста, который реализует преобразование входного текстового сообщения в формат, пригодный для подачи в модель. Пользователь вводит текст через интерфейс, после чего

данный текст передаётся в токенизатор. На этом этапе выполняется разбиение текста на токены, добавление специальных токенов начала и конца последовательности, а также выравнивание длины последовательности до фиксированного значения. Дополнительно формируются вспомогательные структуры, такие как маска внимания, необходимая для корректной работы трансформерной архитектуры.

Ключевым компонентом является модуль предсказаний, реализующий применение обученной модели к входным данным. На вход модели подаются числовые представления текста, полученные на предыдущем этапе. Внутри модели выполняется последовательность преобразований, включающая обработку входной последовательности слоями трансформера и последующую классификацию на основе выходного представления. На практике это реализуется через прямой вызов модели с передачей параметров `input_ids` и `attention_mask`.

Результатом работы модели является вектор логитов — числовых значений, соответствующих каждому классу тональности. Для получения интерпретируемого результата применяется операция выбора максимального значения, в результате чего определяется наиболее вероятный класс. Дополнительно может выполняться нормализация логитов с использованием функции `softmax` для получения вероятностного распределения по классам.

Параллельно работает модуль тематического моделирования. На вход передаются очищенные тексты. Сначала выполняется векторизация с помощью, после чего формируется матрица признаков. Далее эта матрица передается в модель LDA. После завершения вычислений модуль формирует матрицу распределения тем, доминирующую тему документа, вероятность принадлежности документа каждой теме. Результаты интегрируются обратно в основной датасет в виде дополнительных полей `topic_id` и `topic_probability`.

Использование общей структуры данных позволило объединить результаты разных аналитических блоков без дополнительной синхронизации.

После завершения тематического и тонального анализа данные поступают в модуль временной агрегации. Взаимодействие реализовано через передачу объекта `DataFrame`, содержащего временные метки публикаций, тематические вероятности и результаты анализа тональности. На данном этапе средствами выполняется группировка данных по временным периодам и на основе агрегированных данных вычисляются интенсивность тем, динамика изменений и интегральный индекс тенденций. Все промежуточные результаты сохраняются в отдельной аналитической таблице.

Отдельное внимание в реализации уделено пользовательскому интерфейсу, который обеспечивает взаимодействие пользователя с системой. Интерфейс реализован с использованием библиотеки `Streamlit`, преобразовывающей скрипты на Python в веб-приложения, визуализирующей данные и управляющая ими. Получившаяся страница представляет собой веб-приложение с минималистичным дизайном [3.5]. В интерфейсе предусмотрено текстовое поле для ввода новостного сообщения и кнопка запуска анализа. После ввода текста и активации анализа происходит передача данных в модуль предобработки, затем в модель, после чего результат классификации отображается пользователю. Также можно посмотреть выявления тенденций. Результат запуска `Streamlit` представлен на Рисунке 3.2.




Рисунок 3.2 — Пример пользовательского интерфейса

Таким образом, взаимодействие компонентов организовано в виде линейного конвейера, где выход одного этапа является входом следующего. Такой подход обеспечивает простоту реализации, прозрачность работы системы и возможность масштабирования.

В процессе реализации были учтены особенности работы с трансформерными моделями, включая необходимость использования графических ускорителей. Модель размещается на устройстве CUDA, что позволяет существенно ускорить процесс обработки текстов. При этом интерфейс взаимодействует с моделью через единый программный слой, скрывающий детали аппаратной реализации [3.6].

Дополнительно реализована возможность пакетной обработки текстов, что позволяет применять модель не только к отдельным сообщениям, но и к массивам новостных публикаций. Это обеспечивает расширяемость системы и её применение в задачах анализа больших новостных потоков.

Связь между компонентами программной реализации осуществляется через передачу структурированных данных. На каждом этапе используются стандартизированные форматы представления информации: строки текста, токенизированные последовательности и числовые тензоры. Это обеспечивает согласованность работы всех модулей и упрощает их интеграцию.

Диаграмма, отображающая взаимодействие компонентов, представлена на Рисунке 3.3.




Рисунок 3.3 — Диаграмма взаимодействия компонентов

В итоге реализованная система представляет собой интегрированное программное решение, в котором компоненты сбора данных, обработки текста, модели машинного обучения и пользовательского интерфейса взаимодействуют как единое целое. Такая архитектура обеспечивает автоматизированный анализ тональности новостных публикаций и позволяет использовать разработанное решение для практических задач исследования информационных потоков.

3.2 Анализ полученных результатов

3.2.1 Описание и реализация методологии тестирования и валидации

На заключительном этапе разработки была проведена процедура тестирования и валидации, направленная на оценку качества работы и его способности корректно классифицировать тексты научно-технологической тематики. Методология тестирования основывалась на использовании случайной выборки новостных публикаций, размеченной вручную.

После завершения обучения выполнялась оценка качества модели. Для сравнения базовой версии и дообученной модификации был сформирован внешний сравнительный датасет, размеченный средствами аналитической платформы PolyAnalyst. Создание разметки представлено на Рисунке 3.4.




Рисунок 3.4 — Получение тональности с помощью ПО PolyAnalyst

Для оценки качества разработанного решения было проведено сравнение двух моделей: базовой модели анализа тональности и дообученной модели, адаптированной под предметную область. В качестве основных метрик качества использовались accuracy, precision, recall и F1-score. Метрика accuracy отражает долю правильно классифицированных объектов, однако в условиях несбалансированных классов более информативной является метрика F1-score, позволяющая учитывать как точность, так и полноту классификации.

Сравнение метрик моделей представлено на Рисунке 3.5.

Сводка по метрикам (Базовая модель):				
	precision	recall	f1-score	support
NEGATIVE	0.220	0.518	0.309	18194
NEUTRAL	0.607	0.520	0.560	55621
POSITIVE	0.332	0.064	0.108	20629
accuracy			0.420	94444
macro avg	0.386	0.367	0.326	94444
weighted avg	0.473	0.420	0.413	94444
Общая точность (Accuracy): 0.4200				
Сводка по метрикам (Дообученная модель):				
	precision	recall	f1-score	support
NEGATIVE	0.803	0.820	0.811	18194
NEUTRAL	0.862	0.884	0.875	55621
POSITIVE	0.823	0.800	0.810	20629
accuracy			0.835	94444
macro avg	0.829	0.835	0.832	94444
weighted avg	0.842	0.853	0.848	94444
Общая точность (Accuracy): 0.8350				

Рисунок 3.5 — Сравнение качества моделей

Проведенное тестирование показало, что после предметно-ориентированного дообучения модели RuBERT общая согласованность с внешней системой разметки PolyAnalyst увеличилась с 0,42 до 0,84. Сравнительный анализ метрик базовой и дообученной моделей классификации тональности позволяет сделать вывод о радикальном повышении качества автоматизированной обработки текстов. Общая точность классификации увеличилась ровно в два раза, поднявшись с критически низкой отметки в сорок два процента до высокого показателя в восемьдесят четыре процента. Наиболее значимый прогресс зафиксирован в распознавании положительной тональности: если базовая модель фактически игнорировала данный класс, идентифицируя лишь шесть процентов позитивных новостей, то дообученная версия

продемонстрировала полноту охвата в восемьдесят процентов. Это свидетельствует о качественном преодолении неспособности алгоритма улавливать специфическую эмоциональную окраску и лексические нюансы в рамках научно-технологического корпуса.

После завершения тестирования блока анализа тональности была проведена проверка качества тематического моделирования.

Для оценки тематической структуры использовалась метрика *semantic coherence*, рассчитываемая средствами библиотеки *gensim*. Обучение LDA-моделей проводилось для различных значений числа тем в диапазоне от 4 до 10. Для каждой модели вычислялось значение *coherence score*. График представлен на Рисунке 3.6.




Рисунок 3.6 — Сравнение качества моделей

Максимальное и наиболее устойчивое значение было получено при 8 темах.

Границы между научно-технологическими областями формировались на основе доминирующих лексических кластеров. Для каждой темы рассчитывался набор наиболее вероятных терминов, обладающих максимальным вкладом в её формирование. Именно эти устойчивые словесные группы выступали основным критерием интерпретации тематик и определения их содержательных границ.

После получения вероятностных тем выполнялась их интерпретация. Название каждой области определялось не по отдельному слову, а по совокупности наиболее значимых терминов, их смысловой взаимосвязи и характеру публикаций, имеющих максимальную вероятность принадлежности к данной теме. Ключевые слова представлены на Рисунке 3.7.

НАЙДЕННЫЕ ТЕМЫ:	
Тема 0:	смартфон, apple, новый, устройство, компания, пользователь, windows, специалист, microsoft, девайс,
Тема 1:	учёный, человек, исследование, исследователь, результат, процент, работа, новый, клетка, оказаться
Тема 2:	iphone, игра, новый, выйти, разработчик, компания, sony, консоль, хороший, часть
Тема 3:	спутник, запуск, космический, ракета, полёт, запустить, наса, космический аппарат, станция, роскосмос
Тема 4:	учёный, земля, звезда, планета, обнаружить, объект, масса, солнце, наблюдение, результат
Тема 5:	российский, самолёт, ракета, новый, дрон, комплекс, беспилотник, система, военный, машина
Тема 6:	компания, сша, производство, рынок, китаи, страна, доллар, продажа, стоимость, поставка
Тема 7:	слово, заявить, рассказать, россия, система, отметить, специалист, технология, российский, создание

Рисунок 3.7 — Топ слов для 8 тем

Первая выделенная область была интерпретирована как информационные технологии. Основанием для такой интерпретации стали устойчиво встречающиеся слова: смартфон, apple, устройство, пользователь, windows, microsoft, девайс, компания. Ядро данной группы формируется вокруг потребительской электроники, мобильных устройств, программных платформ и цифровых сервисов. Границы этой области проходят по признаку массовых информационных технологий и пользовательских цифровых решений. Если в

публикации доминируют термины, связанные с программным обеспечением, аппаратным обеспечением, мобильными платформами или крупными IT-компаниями, документ получает высокий тематический вес в данной области.

Вторая область была определена как научные разработки и исследования. Её ядро формируется словами: учёный, человек, исследователь, результат, клетка, работа, новый, процент. Здесь смысловая граница определяется наличием научной методологии, экспериментальной деятельности, публикации результатов или биомедицинских наблюдений. В данную категорию попадают материалы о лабораторных экспериментах, медицинских разработках, биологических открытиях и фундаментальных научных публикациях. Дополнительный анализ эволюции ключевых слов показал, что со временем внутри данной тематики усилилась медицинская и нейробиологическая направленность, что проявляется через появление терминов мозг, пациент, препарат, клетка.

Третья область была интерпретирована как цифровые развлечения. Ключевые слова данной группы: iphone, игра, разработчик, sonu, консоль, выйти, компания. Граница этой тематики определяется публикациями, связанными с игровой индустрией, цифровым медиаконтентом, пользовательскими развлекательными платформами и рынком интерактивных технологий. На ранних временных этапах доминировали публикации о игровых проектах и консольных решениях, что подтверждает устойчивость данной смысловой группы.

Четвёртая область была определена как космические технологии. Основу темы составили слова: спутник, запуск, космический, ракета, полёт, nasa, станция, роскосмос. Тематическая граница здесь формируется через присутствие терминов, связанных с космическими миссиями, орбитальными платформами, ракетными технологиями и международными космическими программами. Если публикация содержит упоминания запусков, спутниковых аппаратов, пилотируемых миссий или деятельности космических агентств, документ получает высокий вклад в данную область.

Пятая область получила название естественные науки. Её словарь включает: земля, звезда, планета, объект, масса, солнце, наблюдение. Границы данной темы формируются публикациями, связанными с астрофизикой, астрономическими наблюдениями, изучением космических объектов, геофизическими процессами и фундаментальными законами природы. В отличие от темы космоса, где акцент делается на инженерной составляющей, данная область отражает научное изучение природных явлений и физических процессов.

Шестая область была интерпретирована как военные технологии. Её ключевые слова: самолёт, ракета, дрон, комплекс, беспилотник, система, военный, машина. Граница этой тематики определяется технологическими публикациями, связанными с оборонной промышленностью, системами вооружения, авиационными платформами и беспилотными технологиями. Дополнительный временной анализ показал, что внутри данной области происходило заметное смещение от авиационных систем к беспилотным комплексам, что подтверждается постепенным усилением терминов дрон и беспилотник в последние временные периоды.

Седьмая область была определена как мировая экономика и международные рынки. Её словарь включает: компания, производство, рынок, кита́й, страна, доллар, продажа, стоимость, поставка. Тематическая граница данной области формируется через экономические публикации, отражающие международную конкуренцию, производственные цепочки, рыночные процессы и глобальные технологические поставки. Особенностью данной темы является связь технологического развития с экономическими механизмами и промышленным производством.

Восьмая область была интерпретирована как общие технологические разработки и инновации. Ключевые слова темы: система, технология, специалист, создание, российский, заявить, разработка. В отличие от специализированных направлений, данная область объединяет публикации, посвящённые новым технологическим решениям, межотраслевым разработкам,

прикладным инновациям и инженерным проектам. Граница этой тематики определяется отсутствием жёсткой отраслевой специализации при сохранении явного технологического контекста.

Дополнительная верификация выделенных областей выполнялась через анализ временной эволюции ключевых слов. Для каждой темы строились двухлетние временные окна, внутри которых анализировались наиболее характерные термины. Такой подход позволил не только подтвердить устойчивость тематических границ, но и проследить внутреннюю эволюцию самих направлений. Например, в области военных технологий было выявлено смещение от классической авиационной техники к автономным беспилотным системам. В тематике научных разработок наблюдался переход от общих публикаций о цифровых продуктах к биомедицинским направлениям. В космической тематике усилилось присутствие терминов, связанных с прикладными космическими миссиями и национальными программами.

Представленный график на Рисунке 3.8 иллюстрирует динамику присутствия восьми научно-технологических тем в российском новостном пространстве с 2006 по 2025 год с последующим прогнозом до 2028 года.




Рисунок 3.8 — Прогноз присутствия тем в российском информационном пространстве

Использование метода экспоненциального сглаживания позволило нивелировать краткосрочные шумы и выявить устойчивые тренды. Прогноз отражает ожидаемую динамику присутствия научно-технологических тем в российском новостном пространстве при сохранении наблюдаемой динамики. Анализ подтверждает вытеснение старой технологической повестки (тема 2) новой, более агрессивно растущей (тема 5). Согласно прогнозу, в ближайшие три года российское научно-технологическое пространство будет максимально сконцентрировано вокруг научных исследований и военных технологий.

С целью перехода от анализа отдельных текстов к исследованию динамики информационного потока была реализована процедура агрегирования результатов классификации. Для этого категориальные значения тональности текстов были преобразованы в числовую шкалу: негативной тональности соответствовало значение -1 , нейтральной — 0 , положительной — $+1$. На Рисунке 3.9 представлен график, который показывает среднюю динамику тональности в текстах по различным темам.




Рисунок 3.9 — Изменение средней тональности по темам

Для информационных технологий характерна в целом положительная тональность, которая, однако, заметно снижается в периоды введения санкций и технологических ограничений. В то же время научная повестка постепенно становится более позитивной, что обусловлено ростом значимости науки и

расширением государственной поддержки исследований. Сектор цифровых развлечений демонстрирует волатильность: высокий уровень позитива начала 2010 годов сменился спадом на фоне ужесточения регулирования цифровой среды, после чего интерес к теме вновь начал расти. Тональность в сфере космоса напрямую коррелирует с успехами космических программ и проведением крупных запусков. Позитивное восприятие естественных наук укрепляется в моменты повышения общественного интереса к медицине, биотехнологиям и вопросам здравоохранения, а сектор военных технологий демонстрирует рост позитивного фона на фоне модернизации армии и усиления внимания к оборонным разработкам. Наиболее подверженной негативным колебаниям темой остается мировой экономики, что вызвано влиянием кризисов, санкций и общей экономической нестабильности. Напротив, общие технологические разработки и инновации сохраняют устойчиво позитивный фон благодаря активному развитию искусственного интеллекта, автоматизации и цифровой экономики в нашей стране.

На основе полученных значений была рассчитана тональность новостного сообщения как взвешенная сумма тональности заголовка и основного текста, где больший вес был присвоен тексту (0,7) по сравнению с заголовком (0,3) [3.7]. Такое взвешивание обусловлено тем, что основной текст содержит более полное и контекстно насыщенное описание события, тогда как заголовок выполняет преимущественно краткую информативную функцию. Далее был сформирован временной ряд, отражающий среднюю тональность новостей по каждой дате, результат представлен на Рисунке 3.10.




Рисунок 3.10 — Динамика тональности новостей

График характеризуется постоянными резкими скачками как вверх, так и вниз. Это говорит о том, что новостной фон крайне чувствителен к событиям: позитивные и негативные инфоповоды сменяют друг друга очень быстро.

Для более наглядного выявления тенденций была применена процедура сглаживания временного ряда с использованием скользящего среднего с окном сглаживания в 30 дней [3.8]. Соответствующий график позволяет выделить долгосрочные тренды и снизить влияние случайных колебаний. Результат представлен на Рисунке 3.11.



Рисунок 3.11 — Сглаженная динамика тональности

Полученные результаты демонстрируют наличие устойчивых периодов изменения тональности, что может быть связано с активным развитием отдельных направлений науки или, напротив, с возникновением проблемных ситуаций. Новостной фон за последние 20 лет стал чуть более позитивным в среднем, но остается очень нестабильным и подверженным резким краткосрочным колебаниям.

На Рисунке 3.12 представлен анализ ошибок классификации, позволивший выявить наиболее сложные случаи для модели.

	text	my	fine
3	Международная команда исследователей показала,...	NEUTRAL	POSITIVE
6	Все современные птицы произошли от существ, ко...	NEUTRAL	POSITIVE
8	Ученые из израильского медицинского центра име...	NEUTRAL	POSITIVE
11	Ученые Университета Южной Калифорнии определил...	NEGATIVE	POSITIVE
16	Симптомы у переболевших COVID-19 сохраняются в...	NEGATIVE	POSITIVE
21	Ученые Бостонского университета выяснили, что ...	NEGATIVE	POSITIVE
22	Российские ученые предположили, что коронавиру...	NEGATIVE	POSITIVE
25	Ученые Массачусетского технологического инстит...	NEUTRAL	POSITIVE
26	Иранский математик и единственная женщина, пол...	NEGATIVE	POSITIVE
28	Медики из Клинического исследовательского инст...	NEGATIVE	POSITIVE

Рисунок 3.12 — Сложные примеры

К таким случаям относятся новости с нейтральной формулировкой, содержащие скрытую положительную или отрицательную оценку, а также тексты с неоднозначной интерпретацией. Наличие подобных примеров объясняет снижение качества классификации для класса POSITIVE.

На Рисунке 3.13 представлен график индекса тональности для первых четырех тем.




Рисунок 3.13 — Индекс тенденций в российском информационном пространстве

Анализ выявил высокую волатильность всех четырех тематических направлений с колебаниями индекса тенденций от $-1,5$ до $+1,5$, что отражает динамичную природу новостных потоков. Наиболее выраженный рост и устойчивый положительный прогноз демонстрирует тема «Научные

исследования», что, вероятно, обусловлено приоритетами государственной политики и увеличением финансирования науки. Второе место по значимости занимает направление «Космос», также сохраняющее позитивную динамику благодаря реализации масштабных космических программ. Сектор информационных технологий показывает умеренный, но стабильный рост, несмотря на высокую волатильность, связанную с быстрыми изменениями в индустрии. В то же время для темы «Цифровые развлечения» зафиксирован наименее благоприятный прогноз, свидетельствующий о смещении интереса аудитории в сторону прикладных решений. Динамика 2020-2025 годов подтверждает четкую дифференциацию трендов с явным приоритетом фундаментальной науки и космоса, что указывает на глубокую стратегическую переориентацию российского информационного пространства.

На Рисунке 3.14 представлен график индекса тональности для следующих четырех тем.




Рисунок 3.14 — Индекс тенденций в российском информационном пространстве

Анализ графика прогнозирования научно-технологических тенденций демонстрирует высокую динамику информационного фона и подтверждает работоспособность разработанной модели в условиях реального новостного потока. Все четыре тематических направления характеризуются значительной волатильностью интегрального индекса в диапазоне от $-1,5$ до $+1,5$, что отражает

чувствительность медиапространства к внешним событиям, изменениям государственной политики и глобальным технологическим сдвигам. Горизонтальные пунктирные линии на уровнях 0 и 1 выступают в качестве порогов, разделяющих фазы спада, стагнации и выраженного роста интереса к тематике.

Наиболее устойчивый восходящий тренд демонстрирует тема 5 «Военные технологии»: после глубокого спада в 2007–2008 годах индекс восстановился, достиг экстремального пика около 2018 года и с 2020 года стабильно растёт, достигая к 2025 году значения 0,7. Прогнозная пунктирная линия указывает на дальнейшее усиление данного направления, что коррелирует с приоритетами модернизации оборонно-промышленного комплекса и увеличением объёма соответствующих публикаций. Тема 7 «Общие технологические разработки и инновации» показала самый высокий исторический пик 1,4 в 2014 году, отражающий период активной цифровизации и внедрения инноваций, после чего индекс стабилизировался в положительной зоне; прогноз также указывает на умеренный, но устойчивый рост, подтверждающий долгосрочный фокус информационного пространства на технологическом суверенитете. Тема 4 «Естественные науки» демонстрирует циклическую динамику с пиками в 2009 и 2016 годах, вероятно связанными с этапами финансирования государственных научных программ и публикацией прорывных исследований; к 2025 году индекс стабилизировался около нулевой отметки, а прогнозная траектория предполагает постепенное восстановление интереса. Тема 6 «Мировая экономика и международные рынки» наиболее подвержена внешним шокам: резкий спад около 2014 года сменился волатильным восстановлением, а к 2025 году индекс вернулся к нейтральной зоне; прогнозная линия указывает на стабилизацию или незначительное снижение, что отражает адаптацию новостного фона к новым макроэкономическим реалиям и переориентацию аналитического дискурса.

В разработанной модели тональность рассматривается не как дополнительная характеристика текста, а как один из факторов, напрямую влияющих на формирование и развитие научно-технологических тенденций в

информационном пространстве. Такой подход связан с тем, что новостной поток отражает не только факт появления технологии или научного результата, но и реакцию общества, бизнеса, экспертного сообщества и государства на происходящие изменения. Именно эмоциональный контекст информационного сопровождения во многих случаях определяет скорость распространения технологии, уровень общественного доверия к ней, инвестиционную привлекательность направления и интенсивность дальнейшего информационного освещения.

Если рассматривать научно-технологическое развитие как динамическую систему, то можно отметить, что рост числа публикаций сам по себе ещё не свидетельствует о формировании устойчивого тренда. Увеличение информационного присутствия может быть вызвано как позитивным интересом к инновации, так и кризисными событиями, технологическими сбоями или общественными опасениями. По этой причине в рамках разработанной модели в интегральный индекс тенденции была включена не только частота упоминаний темы и её временная динамика, но и эмоциональный фон публикаций. Это позволило перейти от оценки «сколько говорят о технологии» к анализу «как именно о ней говорят».

Анализ полученных временных графиков показывает, что изменение тональности действительно выступает одним из факторов усиления или ослабления научно-технологических направлений.

Наиболее показательным примером является тема «Научные исследования». На графике данное направление демонстрирует наиболее выраженный рост интегрального индекса в последние временные периоды. При этом рост обусловлен не только увеличением числа публикаций, но и изменением смыслового наполнения темы. Если в ранних периодах внутри тематики преобладали слова, связанные с игровыми технологиями и цифровыми продуктами, то начиная примерно с середины временного интервала происходит переход к биологическим, медицинским и фундаментальным направлениям: появляются термины клетка, мозг, пациент, препарат, вирус, коронавирус.

Подобная перестройка указывает на смещение общественного внимания в сторону жизненно важных научных разработок. Дополнительный вклад в рост индекса обеспечивается более выраженным нейтрально-позитивным информационным фоном, поскольку публикации о медицинских открытиях, новых препаратах и биотехнологиях, как правило, формируют ожидание практической пользы. В результате данная тема показывает наиболее сильный и статистически подтверждённый рост.

Схожая картина наблюдается в теме «Информационные технологии». Несмотря на наличие колебаний в разные периоды, в последние годы фиксируется устойчивая положительная динамика. Анализ эволюции ключевых слов показывает, что ранние публикации были связаны преимущественно с рынком электроники и коммерческими продуктами, тогда как позднее усиливается присутствие более стратегических технологических терминов. В информационном пространстве IT-сфера чаще сопровождается позитивным или нейтрально-позитивным фоном, поскольку публикации обычно связаны с выпуском новых устройств, цифровыми сервисами, внедрением платформенных решений и технологическим прогрессом. Подобный эмоциональный фон способствует формированию устойчивого общественного интереса и поддерживает рост тематического индекса.

Особый интерес представляет тема «Космос». На графиках данное направление также демонстрирует устойчивый рост, особенно в последние временные интервалы. При анализе ключевых слов видно, что тема сохраняет стабильное тематическое ядро: спутник, запуск, ракета, полёт, NASA, Роскосмос. Это указывает на высокую тематическую устойчивость. Эмоциональный фон подобных публикаций в большинстве случаев формируется вокруг достижений, запусков, успешных миссий или международных проектов, что создаёт позитивный информационный контекст. Даже при наличии отдельных неудач в отрасли доминирует восприятие космических технологий как символа научного прогресса. Это поддерживает рост интегрального индекса и объясняет положительный тренд.

Интересная динамика прослеживается в теме «Военные технологии». В отличие от гражданских технологий, данная область характеризуется более сложным эмоциональным фоном. С одной стороны, рост числа публикаций связан с высоким общественным вниманием к оборонным разработкам. С другой стороны, тональность таких публикаций может варьироваться от позитивной в контексте технологических достижений до негативной при описании конфликтов, рисков и международной напряжённости. Анализ эволюции слов показывает смещение от традиционной авиационной техники к беспилотным системам и автономным платформам: дрон, беспилотник, система, аппарат. Несмотря на потенциально более поляризованный эмоциональный фон, высокая интенсивность информационного обсуждения и технологическая значимость направления обеспечили положительную динамику темы.

Противоположная ситуация наблюдается в теме «Цифровые развлечения», которая по статистическим результатам демонстрирует снижение. На ранних этапах тема активно формировалась вокруг игровой индустрии, новых релизов, консольных платформ и пользовательского контента. Однако в дальнейшем информационный интерес начал снижаться. Одной из причин может выступать изменение эмоционального восприятия отрасли. По мере насыщения рынка публикации о развлекательных технологиях перестают восприниматься как инновационный прорыв и переходят в категорию фонового контента. В результате снижается как интенсивность новостного освещения, так и эмоциональная вовлечённость аудитории, что отражается в отрицательной динамике интегрального индекса.

Похожая ситуация наблюдается в теме «Мировая экономика и международные рынки». Несмотря на высокую частоту появления подобных публикаций, эмоциональный фон экономических новостей часто связан с рыночной нестабильностью, санкционным давлением, валютными колебаниями и логистическими ограничениями. Подобный информационный контекст снижает общий индекс развития даже при сохранении высокого количества публикаций. Это демонстрирует, что высокий объём информационного потока

без позитивного или конструктивного эмоционального сопровождения не всегда приводит к формированию устойчивой технологической тенденции.

Отдельного внимания заслуживает тема «Общие технологические разработки и инновации». По графикам видно, что данное направление демонстрирует стабильный рост без резких провалов. Это может объясняться тем, что публикации данной категории чаще связаны с запуском новых решений, презентацией технологий, инженерными инициативами и прикладными разработками. Подобный информационный фон обычно воспринимается как нейтрально-позитивный и формирует устойчивое восприятие технологического прогресса, что положительно влияет на итоговый индекс.

Визуализация результатов тестирования была выполнена с использованием графиков временных рядов, распределений и сравнительных диаграмм. Полученные графические материалы позволяют наглядно продемонстрировать как качество работы модели, так и возможности её применения для анализа научно-технологических тенденций.

3.2.2 Сравнительный анализ и оценка эффективности с существующими решениями

Сравнительный анализ разработанного решения выполнялся с целью оценки его эффективности относительно существующего базового подхода анализа тональности текстов на русском языке без предметной адаптации. В качестве базового решения использовалась модель RuBERT, применяемая в стандартной конфигурации без дополнительного дообучения на корпусе научно-технологических новостей. Разработанная модель представляет собой дообученную версию той же архитектуры, адаптированную под специфику предметной области [3.9].

Дополнительно были построены графики распределения предсказанных классов (Рисунок 3.15), позволяющие визуально оценить изменения в поведении модели после дообучения.




Рисунок 3.15 — Сравнение распределения предсказаний моделей

Дообучение модели RuBERT привело к изменению распределения тональности. Модель стала гораздо чаще классифицировать высказывания как нейтральные и положительные, при этом резко снизив количество отрицательных. На Рисунке 3.16 представлено изменение предсказаний после дообучения.

NEUTRAL	→	NEUTRAL	28923
NEGATIVE	→	NEGATIVE	9424
POSITIVE	→	POSITIVE	1320
NEUTRAL	→	NEGATIVE	16686
NEUTRAL	→	POSITIVE	10012
POSITIVE	→	NEUTRAL	12377
POSITIVE	→	NEGATIVE	6932
NEGATIVE	→	NEUTRAL	6004
NEGATIVE	→	POSITIVE	2766

Рисунок 3.16 — Сдвиг предсказаний после дообучения

Большая часть текстов, ранее классифицированных как негативные, теперь считаются нейтральными или позитивными. В целом, наблюдается тенденция к «смягчению» тональности. Тексты, которые раньше были негативными или нейтральными, теперь чаще трактуются как положительные. Дообучение

позволило модели эффективно скорректировать пессимистичность новостей, значительно улучшив распознавание позитивных и нейтральных высказываний.

Для статистической проверки значимости различий в результатах был применён критерий Мак-Нимара, предназначенный для сравнения двух классификаторов на одинаковых выборках [3.10]. Данный критерий основывается на анализе несогласованных предсказаний моделей и позволяет определить, являются ли наблюдаемые различия случайными или статистически значимыми.

На основе предсказаний обеих моделей относительно эталонной разметки была сформирована таблица сопряжённости, включающая случаи, когда:

- обе модели дают корректный результат (35000);
- обе модели допускают ошибку (10917);
- базовая модель ошибается, а дообученная модель даёт корректный ответ (43861);
- дообученная модель ошибается, а базовая модель даёт корректный ответ (4666).

Анализ структуры таблицы показывает существенное преобладание ситуаций, в которых дообученная модель корректно классифицирует объекты, ошибочно определяемые базовой моделью. При этом обратные случаи встречаются значительно реже, что указывает на систематическое преимущество дообученного решения.

Значение $p\text{-value}$, полученное в результате применения критерия Мак-Нимара, составило $2,2 \times 10^{-16}$.

Данное значение значительно меньше стандартного уровня статистической значимости (0,05), что позволяет отвергнуть нулевую гипотезу о равенстве качества двух моделей. Таким образом, различия между базовой и дообученной моделями являются статистически значимыми и не могут быть объяснены случайными колебаниями выборки.

В современном ландшафте решений для анализа тональности новостей выделяется несколько ключевых подходов, каждый из которых обладает

специфическими ограничениями. Лексикон-ориентированные методы, опирающиеся на готовые словари вроде RuSentiLex, характеризуются высокой интерпретируемостью, однако демонстрируют низкую точность (0,40–0,55) на сложных научных текстах из-за игнорирования контекста и неспособности распознавать иронию. Классические модели машинного обучения, такие как логистическая регрессия или SVM с векторизацией TF-IDF, показывают более высокие результаты (до 0,70), но теряют семантические связи и плохо справляются с длинными текстами. В свою очередь, современные предобученные трансформеры (базовый RuBERT) и коммерческие API-решения (Google NLP, Yandex) часто остаются недостаточно эффективными в узкоспециализированных областях, показывая точность около 0,54–0,70 из-за ориентации на общие данные и «закрытости» алгоритмов адаптации.

Разработанная в рамках данного исследования дообученная модель RuBERT демонстрирует качественное превосходство над аналогами, достигая показателя точности 0,84. Ключевым преимуществом данного решения является глубокая доменная адаптация под специфику научно-технологического корпуса, что позволяет модели корректно интерпретировать профессиональную терминологию и улавливать скрытую тональность, недоступную базовым алгоритмам.

Помимо анализа тональности была проведена оценка эффективности разработанного блока выявления научно-технологических тенденций. В отличие от классических систем анализа тональности, существующие решения, как правило, ограничиваются классификацией текстов и не выполняют анализ долгосрочной динамики тематик. В разработанной системе дополнительно реализован модуль тематического моделирования, временной агрегации и статистической проверки устойчивости трендов.

Для каждой из восьми выделенных тематик строилась линейная регрессионная модель изменения интегрального индекса тенденций во времени. На основе коэффициента наклона определялось направление изменения

интереса к теме, а по p-value оценивалась статистическая значимость выявленного тренда. Результат представлен на Рисунке 3.17.

	topic	slope	p_value	R2	direction	significance
1	topic_1	0.0747	0.000000	0.8079	рост	значимый
7	topic_7	0.0524	0.001190	0.4508	рост	значимый
4	topic_4	0.0405	0.002084	0.4175	рост	значимый
3	topic_3	0.0360	0.001970	0.4209	рост	значимый
5	topic_5	0.0301	0.006205	0.3478	рост	значимый
0	topic_0	0.0099	0.316833	0.0556	рост	незначимый
6	topic_6	-0.0163	0.005360	0.3575	снижение	значимый
2	topic_2	-0.0169	0.001586	0.4340	снижение	значимый

Рисунок 3.17 — Статистическая оценка трендов

Статистический анализ показал, что для 7 из 8 тематик были выявлены направленные изменения, из которых 6 тематик продемонстрировали статистически значимые тренды при уровне значимости меньше 0,05. Особенно выраженный рост был зафиксирован для темы 1, где коэффициент детерминации составил 0,8079. Это означает, что более 80% вариации индекса объясняется временным фактором, что свидетельствует о высокой устойчивости выявленного тренда.

Разработанная модель демонстрирует более высокую эффективность по сравнению с существующими решениями и способна учитывать специфику научно-технологических новостей. Полученные результаты подтверждают целесообразность применения методов дообучения трансформерных моделей для задач анализа тональности в специализированных предметных областях.

ЗАКЛЮЧЕНИЕ

Выпускная квалификационная работа была посвящена разработке модели интеллектуального анализа тональности новостных потоков для выявления научно-технологических тенденций в российском информационном пространстве. Актуальность исследования обусловлена необходимостью автоматизированной обработки больших объемов новостной информации, позволяющей фиксировать изменения научно-технологической повестки без привлечения значительных экспертных ресурсов и ручной разметки.

В ходе выполнения работы был проанализирован процесс формирования новостных потоков научно-технологической тематики, выявлены ограничения традиционных методов обработки текстов, основанных на универсальных языковых моделях и отсутствии учета предметной специфики. Обоснована целесообразность применения методов обработки естественного языка, включая трансформерные архитектуры, для решения задачи классификации тональности и дальнейшего анализа динамики информационного пространства.

Разработана логика функционирования системы, представляющая собой последовательный конвейер обработки данных: от автоматизированного сбора новостных публикаций с использованием разработанного парсера до формирования интегральных показателей тональности, тематической структуры и научно-технологических тенденций.

Ключевым элементом решения стала дообученная модель на основе архитектуры RuBERT, адаптированная к корпусу научно-технологических новостей. Процесс дообучения включал настройку гиперпараметров и использование специализированного корпуса текстов, что позволило повысить качество классификации по сравнению с базовой моделью. В результате точность определения тональности достигла значения 0,84, что подтверждает улучшение согласованности модели с предметной областью.

Дополнительно был реализован модуль тематического моделирования на основе алгоритма латентного размещения Дирихле, позволяющий выделять

скрытые тематические структуры новостного корпуса и формировать вероятностное распределение документов по темам. На основе этого был построен механизм количественного анализа, включающий расчет интенсивности тематик, их динамики и интегрального индекса тенденций. Это позволило перейти от анализа отдельных новостных сообщений к исследованию устойчивых структурных изменений в научно-технологическом информационном пространстве и выявлению долгосрочных трендов.

Построение временных рядов и последующая статистическая обработка позволили выявить ряд устойчивых закономерностей в развитии тематик. Наиболее устойчивую положительную динамику показали темы, связанные с научными разработками, общими технологическими инновациями, космическими технологиями, информационными системами и военнотехническими решениями. Для данных тематик было зафиксировано не только увеличение информационного присутствия, но и статистически подтверждённый рост значений интегрального индекса, что свидетельствует о формировании устойчивого общественного интереса к данным направлениям.

Особенно заметный рост был выявлен в тематике, связанной с научными разработками и фундаментальными исследованиями. Анализ временной динамики показал стабильное увеличение интереса к данной области на протяжении нескольких последовательных периодов. Это может свидетельствовать об усилении роли науки в общественном информационном поле, росте числа публикаций о технологических открытиях и повышении внимания к вопросам научного развития.

Значительный рост также был зафиксирован в тематике общих технологических разработок и инноваций. Стабильное усиление присутствия наблюдалось и в области информационных технологий. Полученная динамика указывает на устойчивое расширение информационного поля, связанного с цифровой трансформацией, внедрением новых технологических решений и развитием инновационной инфраструктуры.

Положительная динамика была выявлена и в тематике космических технологий. На временных графиках прослеживается устойчивый рост индекса, особенно в последние временные периоды. Это позволяет говорить о повышении информационной активности в данной области, росте интереса к космическим программам, спутниковым технологиям и перспективным направлениям аэрокосмического развития.

Одновременно с этим были выявлены направления, демонстрирующие менее выраженную или отрицательную динамику. В частности, тематики, связанные с цифровыми развлечениями и частью экономико-международных процессов, показали отсутствие устойчивого роста либо тенденцию к снижению информационного присутствия. Полученные результаты позволяют предположить перераспределение общественного внимания в сторону более стратегически значимых научно-технологических направлений.

Проведенное тестирование на независимой выборке, а также сравнительный анализ с внешней системой разметки PolyAnalyst подтвердили эффективность разработанного решения. Статистическая проверка различий с использованием критерия Мак-Нимара показала значимость улучшений между базовой и дообученной моделями, что свидетельствует о системном характере полученного результата.

Практическая значимость работы заключается в создании функционирующей системы интеллектуального анализа новостных потоков, позволяющей автоматизировать обработку больших массивов текстовой информации и выявлять научно-технологические тенденции в российском информационном пространстве. Разработанное решение может быть использовано для мониторинга информационной среды, аналитической поддержки принятия решений и дальнейших исследований в области интеллектуального анализа данных.

Поставленная цель выпускной квалификационной работы была достигнута. Полученные результаты подтверждают эффективность применения трансформерных моделей и методов тематического моделирования для анализа

специализированных текстовых корпусов и формирования комплексной оценки динамики научно-технологических тенденций.

The final qualifying work was devoted to the development of a model for the intelligent analysis of the tonality of news streams to identify scientific and technological trends in the Russian information space. The relevance of the research is due to the need for automated processing of large amounts of news information, which makes it possible to capture changes in the scientific and technological agenda without involving significant expert resources and manual markup.

In the course of the work, the process of forming scientific and technological news streams was analyzed, the limitations of traditional text processing methods based on universal language models and the lack of consideration of subject specifics were revealed. The expediency of using natural language processing methods, including transformational architectures, to solve the problem of tonality classification and further analyze the dynamics of the information space is substantiated.

The logic of the system functioning has been developed, which represents a sequential data processing pipeline: from automated collection of news publications using the developed parser to the formation of integral indicators of tonality, thematic structure and scientific and technological trends.

A key element of the solution was a fully trained model based on the RuBERT architecture, adapted to the scientific and technological news corpus. The retraining process included setting up hyperparameters and using a specialized corpus of texts, which improved the classification quality compared to the basic model. As a result, the accuracy of determining the key reached a value of 0.84, which confirms the improved consistency of the model with the subject area.

Additionally, a thematic modeling module based on the Dirichlet latent placement algorithm was implemented, which allows identifying hidden thematic structures of the news corpus and forming a probabilistic distribution of documents by topic. Based on this, a quantitative analysis mechanism was built, including the calculation of the intensity of topics, their dynamics and the integral trend index. This allowed us to move from the analysis of individual news reports to the study of

sustainable structural changes in the scientific and technological information space and the identification of long-term trends.

The construction of time series and subsequent statistical processing made it possible to identify a number of stable patterns in the development of topics. The topics related to scientific developments, general technological innovations, space technologies, information systems and military-technical solutions showed the most stable positive dynamics. For these topics, not only an increase in information presence was recorded, but also a statistically confirmed increase in the values of the integral index, which indicates the formation of a stable public interest in these areas.

A particularly noticeable increase was revealed in the subjects related to scientific research and fundamental research. An analysis of the time dynamics showed a steady increase in interest in this area over several consecutive periods. This may indicate a strengthening of the role of science in the public information field, an increase in the number of publications on technological discoveries and increased attention to issues of scientific development.

Significant growth was also recorded in the field of general technological developments and innovations. A steady increase in the presence was also observed in the field of information technology. The dynamics obtained indicates a steady expansion of the information field associated with digital transformation, the introduction of new technological solutions and the development of innovative infrastructure.

A positive trend was also revealed in the field of space technology. The time charts show a steady increase in the index, especially in recent time periods. This suggests an increase in information activity in this area, an increase in interest in space programs, satellite technologies and promising areas of aerospace development.

At the same time, areas showing less pronounced or negative dynamics were identified. In particular, topics related to digital entertainment and part of economic and international processes have shown a lack of sustained growth or a downward trend in information presence. The results obtained suggest a redistribution of public attention towards more strategically significant scientific and technological areas.

The conducted testing on an independent sample, as well as a comparative analysis with the external PolyAnalyst markup system, confirmed the effectiveness of the developed solution. Statistical verification of the differences using the McNemar criterion showed the importance of improvements between the basic and advanced models, which indicates the systemic nature of the result.

The practical significance of the work lies in the creation of a functioning system for intelligent analysis of news streams, which makes it possible to automate the processing of large amounts of textual information and identify scientific and technological trends in the Russian information space. The developed solution can be used for monitoring the information environment, analytical decision support and further research in the field of data mining.

The set goal of the final qualifying work has been achieved. The results obtained confirm the effectiveness of using transformer models and thematic modeling methods for analyzing specialized text corpora and forming a comprehensive assessment of the dynamics of scientific and technological trends.

СПИСОК ИСТОЧНИКОВ

1 ИССЛЕДОВАТЕЛЬСКИЙ РАЗДЕЛ

1.1 Liu B. Opinion Mining and Sentiment Analysis. Foundations and Trends in Information Retrieval. — М.: Вильямс, 2008. — 168 с.

1.2 Двойникова А. А., Карпов А. А. Аналитический обзор подходов к распознаванию тональности русскоязычных текстовых данных [Электронный ресурс] // Информационно-управляющие системы. — Режим доступа: <https://cyberleninka.ru>.

1.3 Асимметричный анализ тональности деловых новостей [Электронный ресурс] // Блог компании Neoflex на Хабр. — Режим доступа: <https://habr.com/ru/companies/neoflex/articles/589563/>

1.4 Владимир Г. Б., Юрий Н. С., Даниил С. Д. Сравнительный анализ методов машинного обучения и RuBERT для определения достоверности новостных RSS-лент [Электронный ресурс] // Scientific works of KubSTU. — 2026. — № 1. Кудрявцев В.Б., Гасанов Э.Э., Подколзин А.С. Введение в теорию интеллектуальных систем. // М.: Изд-во ф-та ВМиК МГУ, — 2006

1.5 Маньков А. С., Детков А. А. Анализ тональности текста. Сравнение популярных методов // Екатеринбург: Уральский федеральный университет, 2024.

1.6 Ярошенко П.В., Лукашевич Н.В. RusEmoLex: эмоциональный лексикон для русского языка // Russian Journal of Linguistics. - 2025. - Т. 29. - №3. - С. 659-687.

1.7 Topic Modeling Using Latent Dirichlet Allocation (LDA) [Электронный ресурс] // GeeksforGeeks. — 2025. — Режим доступа: <https://www.geeksforgeeks.org/nlp/topic-modeling-using-latent-dirichlet-allocation-lldaru>

1.8 Schmid P. Accelerate BERT Inference with DeepSpeed-Inference on GPUs [Электронный ресурс] // P. Schmid. — Режим доступа: <https://www.philschmid.de/bert-deepspeed-inference>

1.9 Лексические особенности языка научного стиля [Электронный ресурс] // Студопедия. — Режим доступа: https://studopedia.ru/7_63834_leksicheskie-osobennosti-yazika-nauchnogo-stilya.html.

1.10 Трансформеры [Электронный ресурс] / М. Рябинин // Яндекс Практикум. Учебник по машинному обучению. — Режим доступа: <https://education.yandex.ru/handbook/ml/article/transformery>.

1.11 Метрики классификации и регрессии [Электронный ресурс] / М. Буркина, П. Губко, А. Горчаков // Яндекс Практикум. Учебник по машинному обучению. — Режим доступа: <https://education.yandex.ru/handbook/ml/article/metriki-klassifikacii-i-regressii>.

1.12 Schmid P. Accelerate BERT Inference with DeepSpeed-Inference on GPUs [Электронный ресурс] / P. Schmid. — Режим доступа: <https://www.philschmid.de/bert-deepspeed-inference>

2 АНАЛИТИЧЕСКИЙ РАЗДЕЛ

2.1 Наука и техника [Электронный ресурс] // Lenta.ru. — Режим доступа: <https://lenta.ru/rubrics/science/>

2.2 Создание содержимого сайта [Электронный ресурс] // MDN Web Docs (Mozilla Developer Network). — Режим доступа: https://developer.mozilla.org/ru/docs/Learn_web_development/Getting_started/Your_first_website/Creating_the_content

2.3 Beautiful Soup Documentation [Электронный ресурс]. — Режим доступа: <https://beautiful-soup.readthedocs.io/en/latest/>

2.4 JSON: полное руководство по формату обмена данными [Электронный ресурс] // Taurion. — Режим доступа: <https://taurion.ru/article/json>

2.5 HTTP-запросы: GET, POST и другие [Электронный ресурс] / В. Егорцев // Tproger. — Режим доступа: <https://tproger.ru/articles/http-zaprosy--get-post-i-drugie>

2.6 Fine-Tune модели основанной на трансформерах (Rubert) для классификации текстов [Электронный ресурс] // Хабр. — Режим доступа: <https://habr.com/ru/articles/682476/>

2.7 Сириус.Курсы. Глубокое обучение. Версия 1.5 [Электронный ресурс]. — Режим доступа: <https://edu.sirius.online/>

2.8 ReLU Activation Function in Deep Learning [Электронный ресурс] // GeeksforGeeks. — Режим доступа: <https://www.geeksforgeeks.org/deep-learning/relu-activation-function-in-deep-learning>

2.9 TensorFlow: обучение машинному обучению [Электронный ресурс] // TensorFlow (Google). — Режим доступа: <https://www.tensorflow.org/learn?hl=ru>

2.10 PyTorch Documentation [Электронный ресурс] // PyTorch. — Режим доступа: <https://docs.pytorch.org/docs/stable/index.html>

2.11 Transformers Documentation [Электронный ресурс] // Hugging Face. — Режим доступа: <https://huggingface.co/docs/transformers/index>

2.12 Ramage D. A Practical Guide to Latent Dirichlet Allocation. — 2009. — 55с.

3 ТЕХНОЛОГИЧЕСКИЙ РАЗДЕЛ

3.1 RuBERT for Sentiment Analysis (blanchefort/rubert-base-cased-sentiment) [Электронный ресурс] // Платформа Hugging Face. — Режим доступа: <https://huggingface.co/blanchefort/rubert-base-cased-sentiment>

3.2 Практическое применение анализа тональности [Электронный ресурс] // Блог компании OTUS на Хабр. — 2023. — Режим доступа: <https://habr.com/ru/companies/otus/articles/781042>

3.3 Trainer [Электронный ресурс] // Документация Hugging Face Transformers. — Режим доступа: https://huggingface.co/docs/transformers/main_classes/trainer

3.4 Introduction to Machine Learning: Training and Inference [Электронный ресурс] // Linode Documentation. — Режим доступа: <https://www.linode.com/docs/guides/introduction-to-machine-learning-training-and-inference/>

3.5 Streamlit Documentation [Электронный ресурс] // Документация Streamlit. — Режим доступа: <https://streamlit-docs.netlify.app/>

3.6 Использование GPU в WSL [Электронный ресурс] // Microsoft Learn. — Режим доступа: <https://learn.microsoft.com/ru-ru/windows/wsl/tutorials/gpu-compute>

3.7 Применение методов машинного обучения [Электронный ресурс] // Современные наукоемкие технологии. — Режим доступа: <https://top-technologies.ru/article/view?id=39006>

3.8 Нильсен Э. Практический анализ временных рядов: прогнозирование со статистикой и машинное обучение. — М.: ДМК Пресс, 2020. — 544 с

3.9 Оценка качества в задачах классификации и регрессии [Электронный ресурс] // NEERC Wiki. — Режим доступа: https://neerc.ifmo.ru/wiki/index.php?title=Оценка_качества_в_задачах_классификации_и_регрессии

3.10 McNemar's Test using SPSS Statistics [Электронный ресурс] // Laerd Statistics. — Режим доступа: <https://statistics.laerd.com/spss-tutorials/mcnemars-test-using-spss-statistics.php>

ПРИЛОЖЕНИЯ

Приложение А — Презентационный материал

Приложение Б — Листинг кода разработки модели

Приложение А

Презентационный материал




Рисунок А.1 — Первый слайд презентации




Рисунок А.2 — Второй слайд презентации

Обзор существующих решений

Таблица 1 — Сравнение существующих решений

Подход	Основной принцип	Преимущества	Недостатки
Частотно-статистические модели	Отслеживание динамики частоты упоминаний ключевых слов, n-грамм или сущностей во временных рядах	Высокая скорость обработки; простая интерпретация; минимальные вычислительные затраты	Игнорирование семантики и контекста; чувствительность к новостному шуму; отсутствие учёта эмоциональной окраски
Тематическое моделирование	Выделение скрытых тематических распределений (LDA, NMF) и анализ их эволюции по временным срезам	Автоматическое выявление кластеров понятий; количественная оценка интенсивности тем; хорошая интерпретируемость	Необходимость ручной валидации тем; слабая реакция на резкие эмоциональные сдвиги; зависимость от выбора гиперпараметров
Сетевые (графовые) модели	Построение графов соупоминаний или знаний и анализ изменения топологических метрик (центральность, плотность) во времени	Выявление скрытых междисциплинарных связей; наглядность структурных изменений; фиксация диффузии инноваций	Высокая вычислительная сложность; зависимость от качества извлечения сущностей; низкая устойчивость к стилистическому шуму
Гибридные (тональность + ML)	Совместный анализ тематических распределений, контекстной тональности и статистической динамики с использованием нейросетевых классификаторов	Максимальная точность выявления значимых трендов; учёт эмоционального фона и контекста; возможность построения интегральных индексов	Высокие требования к ресурсам и размеченным данным; сниженная интерпретируемость внутренних представлений модели

3

Рисунок А.3 — Третий слайд презентации

Формулировка исследовательской задачи модели

- Цель исследования — разработка модели интеллектуального анализа тональности новостных потоков для выявления научно-технологических тенденций в российском информационном пространстве на основе трансформерных моделей и методов обработки текстовых данных.
- На вход системы поступают новостные публикации, извлекаемые из открытых источников. На выходе формируются оценки тональности сообщений, тематические распределения и агрегированные показатели, используемые для анализа динамики научно-технологических направлений.
- Для достижения цели реализованы этапы: сбор данных, предобработка текстов, классификация тональности с использованием дообученной трансформерной модели, а также последующий анализ результатов, включая тематическое моделирование и выявление тенденций.

4

Рисунок А.4 — Четвертый слайд презентации

Анализ и характеристика входных данных

Таблица 2 — Входные данные

Название признака	Описание	Тип данных
id	уникальный идентификатор записи	Целочисленный
date	дата публикации новости	Дата
year	Год публикации новости	Целочисленный
month	Месяц публикации новости	Целочисленный
day	День публикации новости	Целочисленный
title	Заголовок новости	Текстовый
url	Ссылка на оригинальную страницу новости	Текстовый
text	Основной текст новостного материала	Текстовый

```

Размер датасета: (94444, 8)
id      date      year  month  day  \
0      1  2006-01-03  2006     1     3
1      2  2006-01-04  2006     1     4
2      3  2006-01-04  2006     1     4
3      4  2006-01-05  2006     1     5
4      5  2006-01-06  2006     1     6

title \
0  Создатель iPod стал командором Ордена Британск...
1  Авария шаттла Columbia пережили черви
2  Киты потеряли свой язык
3  "Рональд Рейган" вышел на первое задание
4  Китайцы тестируют пусковую установку лунного м...

url \
0  https://lenta.ru/news/2006/01/03/apple/
1  https://lenta.ru/news/2006/01/04/shuttle/
2  https://lenta.ru/news/2006/01/04/whale/
3  https://lenta.ru/news/2006/01/05/reagan/
4  https://lenta.ru/news/2006/01/06/lunar/

text
0  Джонатан Айви (Jonathan Ive), создатель культо...
1  На борту шаттла Columbia находились подопытные...
2  Киты из разных областей океана могут не понять...
3  Новейший атомный авианосец "Рональд Рейган" от...
4  Китай начал подготовку к запуску искусственног...

```

Рисунок 1 — Пример первых строк

5

Рисунок А.5 — Пятый слайд презентации

Описание этапов разработки модели

- **Сбор данных:** выполнен автоматический сбор новостных публикаций научно-технологической тематики с использованием собственного веб-парсера, извлекающего тексты, заголовки и метаданные с новостного ресурса Lenta.ru.
- **Предобработка данных:** проведена очистка текстов, нормализация, удаление стоп-слов и лемматизация, сформирован единый корпус данных для дальнейшего анализа.
- **Проектирование модели:** определена архитектура решения, включающая блоки анализа тональности на основе трансформерной модели RuBERT, тематического моделирования и модуля выявления тенденций.
- **Реализация анализа тональности:** выполнена токенизация текстов и дообучение предобученной модели RuBERT на корпусе научно-технологических новостей для повышения качества классификации.
- **Тематическое моделирование:** реализован алгоритм LDA для выделения скрытых тематик новостного корпуса и формирования вероятностного распределения документов по темам.
- **Расчет тенденций:** разработан модуль агрегации, включающий расчет интенсивности тем, динамики их изменения и интегрального индекса научно-технологических тенденций.
- **Оценка и валидация:** проведено тестирование модели с использованием метрик качества и статистический анализ значимости выявленных трендов.

6

Рисунок А.6 — Шестой слайд презентации

Обоснование выбора инструментальных средств разработки

Выбор инструментальных средств разработки был обусловлен требованиями к обработке больших объёмов текстовых данных и построению моделей машинного обучения.

- В качестве языка программирования выбран **Python** благодаря широкому набору библиотек для анализа данных и обработки естественного языка.
- Для реализации модели использовались библиотеки **Hugging Face Transformers** и **PyTorch**, обеспечивающие удобную работу с трансформерными архитектурами, включая **RuBERT**
- Для сбора данных применялись библиотеки **requests** и **BeautifulSoup**, что позволило реализовать парсинг новостных источников
- Для тематического моделирования использовался алгоритм, реализованный с применением библиотек **gensim** и **scikit-learn**, что позволило выделить скрытые тематические структуры в корпусе новостей и сформировать вероятностное распределение документов по темам.
- Обработка и анализ данных выполнялись с использованием **pandas** и **matplotlib**
- Разработка и тестирование осуществлялись в среде **Jupyter Notebook**, обеспечивающей наглядность и удобство проведения экспериментов

7

Рисунок А.7 — Седьмой слайд презентации

Описание реализации модели

$$T_{k,t} = w_1 z(V_{k,t}) + w_2 z(G_{k,t}) + w_3 z(S_{k,t})$$

где $V_{k,t}$ — интенсивность темы k в момент времени t ;

$G_{k,t}$ — скорость изменения тематической интенсивности;

$S_{k,t}$ — средняя тональность темы.



Рисунок 2 — Ход реализации модели

Рисунок А.8 — Восьмой слайд презентации

Анализ полученных результатов

найденные темы:

Тема 0:
смартфон, apple, новый, устройство, компания, пользователь, windows, специалист, microsoft, девайс,

Тема 1:
учёный, человек, исследование, исследователь, результат, процент, работа, новый, клетка, оказаться

Тема 2:
iphone, игра, новый, выйти, разработчик, компания, sonu, консоль, хороший, часть

Тема 3:
спутник, запуск, космический, ракета, полёт, запустить, наса, космический аппарат, станция, роскошный

Тема 4:
учёный, земля, звезда, планета, обнаружить, объект, масса, солнце, наблюдение, результат

Тема 5:
российский, самолёт, ракета, новый, дрон, комплекс, беспилотник, система, военный, машина

Тема 6:
компания, сви, производство, рынок, китай, страна, доллар, продажа, стоимость, поставка

Тема 7:
слово, завить, рассказать, россия, система, отметить, специалист, технология, российский, создание

Рисунок 3 — Топ слов

Сводка по метрикам (Базовая модель):				
	precision	recall	f1-score	support
NEGATIVE	0.220	0.518	0.309	18194
NEUTRAL	0.607	0.520	0.560	55621
POSITIVE	0.332	0.064	0.108	20629
accuracy			0.420	94444
macro avg	0.386	0.367	0.326	94444
weighted avg	0.473	0.420	0.413	94444
Общая точность (Accuracy): 0.4200				
Сводка по метрикам (Добученная модель):				
	precision	recall	f1-score	support
NEGATIVE	0.803	0.820	0.811	18194
NEUTRAL	0.862	0.884	0.875	55621
POSITIVE	0.823	0.800	0.810	20629
accuracy			0.835	94444
macro avg	0.829	0.835	0.832	94444
weighted avg	0.842	0.853	0.848	94444
Общая точность (Accuracy): 0.8350				

Рисунок 4 — Сравнение качества моделей

9

Рисунок А.9 — Девятый слайд презентации

Анализ полученных результатов





Рисунок 5 — Изменение средней тональности по темам

10

Рисунок А.10 — Десятый слайд презентации

Анализ полученных результатов



11

Рисунок А.11 — Одиннадцатый слайд презентации

Анализ полученных результатов



12

Рисунок А.12 — Двенадцатый слайд презентации

Заключение

- В ходе выполнения работы был проанализирован процесс формирования новостных потоков научно-технологической тематики и выявлены ограничения существующих подходов к анализу текстовой информации, основанных на использовании универсальных моделей без учета предметной специфики и методов тематической агрегации. На основе проведенного анализа была разработана архитектура системы, представляющая собой последовательный конвейер обработки данных: от автоматизированного сбора новостных публикаций с использованием разработанного парсера до формирования интегральных показателей тональности и научно-технологических тенденций.
- Ключевым элементом разработанного решения стала дообученная трансформерная модель на основе архитектуры RuBERT, адаптированная к корпусу научно-технологических новостей. Для расширения аналитических возможностей дополнительно был реализован модуль тематического моделирования на основе алгоритма LDA (Latent Dirichlet Allocation), позволяющий выделять скрытые тематические структуры и формировать вероятностное распределение документов по темам.

11

Рисунок А.13 — Тринадцатый слайд презентации

Пример работы модели



14

Рисунок А.14 — Четырнадцатый слайд презентации

Благодарю за внимание!

Рисунок А.15 — Пятнадцатый слайд презентации



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное бюджетное образовательное учреждение высшего образования
«МИРЭА - Российский технологический университет»

Институт информационных технологий (ИИТ)

Кафедра прикладной математики

Направление «Прикладная математика»
профиль «Анализ данных»

Выпускная квалификационная работа бакалавра на тему:

«Модель интеллектуального анализа тональности новостных потоков для выявления научно-технологических тенденций в российском информационном пространстве»

Автор: студент группы ИМБО-01-22

Мешкова Людмила Владимировна

Руководитель: д.х.н., профессор, профессор кафедры ПМ

Калач Андрей Владимирович

Москва 2026

Рисунок А.16 — Шестнадцатый слайд презентации

Приложение Б

Листинг Б.1 — Программный код для парсинга, предобработки и сохранения данных

```
import requests
from bs4 import BeautifulSoup
from datetime import datetime, timedelta
import json
import time
BASE_URL =
"https://lenta.ru/rubrics/science/{year}/{month:02d}/{day:02d}/"
start_date = datetime(2005, 1, 1)
end_date = datetime(2025, 12, 31)
output_file = "lenta_science_news.json"
all_news = []
def get_full_text(article_url):
    try:
        res = requests.get(article_url, timeout=10)
        res.raise_for_status()
        soup = BeautifulSoup(res.text, "html.parser")
        paragraphs = soup.select("div.topic-body p, div.article-
body p, div[data-gtm-section='text'] p")
        text = "\n".join(p.get_text(strip=True) for p in
paragraphs if p.get_text(strip=True))
        return text
    current_date = start_date
    while current_date <= end_date:
        url = BASE_URL.format(year=current_date.year,
month=current_date.month, day=current_date.day)
        try:
            response = requests.get(url, timeout=10)
            response.raise_for_status()
            soup = BeautifulSoup(response.text, "html.parser")
            articles = soup.select("section div a")
            for a in articles:
                title = a.get_text(strip=True)
            articles = soup.select("section div a")
            for a in articles:
                title = a.get_text(strip=True)
                href = a.get("href")
                if not href or not title:
                    continue
                if href.startswith("https://"):
                    full_url = href
                else:
                    full_url = "https://lenta.ru" + href
                full_text = get_full_text(full_url)
                if not full_text:
                    continue # если текст не найден, пропускаем
                news_item = {date": current_date.strftime("%Y-%m-%d"),
"title": title, "url": full_url, text": full_text}
                all_news.append(news_item)
```

Листинг Б.2 — Программный код для обучения модели и инференса

```
import pandas as pd
import matplotlib.pyplot as plt
import pymorphy3
import torch
import seaborn as sns

from transformers import AutoTokenizer,
AutoModelForSequenceClassification
from transformers import Trainer, pipeline
from sklearn.metrics import accuracy_score, classification_report,
confusion_matrix
from datasets import Dataset
from sklearn.utils.class_weight import compute_class_weight
import numpy as np
from torch.nn import CrossEntropyLoss
from sklearn.utils import resample

df_train = df[df["sentiment_score"] > 0.83]
min_class = df_train["sentiment"].value_counts().min()
df_train["sentiment"].value_counts()

dataset = Dataset.from_pandas(df_train)
dataset = dataset.train_test_split(test_size=0.2)

train_dataset = dataset["train"]
val_dataset = dataset["test"]

MODEL_NAME = "blanchefort/rubert-base-cased-sentiment"
tokenizer = AutoTokenizer.from_pretrained(MODEL_NAME)

model = AutoModelForSequenceClassification.from_pretrained(
    MODEL_NAME,
    num_labels=3,
    id2label=id2label,
    label2id=label2id
).to("cuda")

training_args = TrainingArguments(
    output_dir="./sentiment_model",
    learning_rate=2e-5,
    per_device_train_batch_size=16,
    per_device_eval_batch_size=16,
    num_train_epochs=3,
    eval_strategy="epoch",
    save_strategy="epoch",
    logging_steps=50,
    load_best_model_at_end=True
)
```

Продолжение Листинга Б.2

```
trainer = Trainer(
    model=model,
    args=training_args,
    train_dataset=train_dataset,
    eval_dataset=val_dataset,
    processing_class=tokenizer,
    compute_metrics=compute_metrics
)
trainer.train()

trainer.save_model("finetuned_rubert_balanced_mini")
tokenizer.save_pretrained("finetuned_rubert_balanced_mini")

def predict(model, tokenizer, texts, batch_size=32):
    model.eval()
    preds = []

    for i in tqdm(range(0, len(texts), batch_size)):
        batch = texts[i:i+batch_size]
        tokens = tokenizer(
            batch,
            padding=True,
            truncation=True,
            max_length=512,
            return_tensors="pt"
        )
        tokens = {k:v.to("cuda") for k,v in tokens.items()}

        with torch.no_grad():
            outputs = model(**tokens)

        logits = outputs.logits
        batch_preds = torch.argmax(logits, dim=1)
        preds.extend(batch_preds.cpu().numpy())
    return preds

finetuned_path = "finetuned_rubert_balanced_midi"
ft_tokenizer = AutoTokenizer.from_pretrained(finetuned_path)
ft_model = AutoModelForSequenceClassification.from_pretrained(
    finetuned_path
).to("cuda")

finetuned_preds = predict(
    ft_model,
    ft_tokenizer,
    texts
)
```


Листинг Б.3 — Программный код для создания веб-интерфейса

```
import streamlit as st
import torch
from transformers import AutoTokenizer,
AutoModelForSequenceClassification

finetuned_path =
r"C:\Users\mila0\Downloads\finetuned_rubert_balanced_midi"
@st.cache_resource

def load_model():
    tokenizer = AutoTokenizer.from_pretrained(finetuned_path)
    model =
AutoModelForSequenceClassification.from_pretrained(finetuned_path
)
    model.eval()
    return tokenizer, model

tokenizer, model = load_model()
st.title("Анализ тональности новостей")

st.write("Введите текст новости:")
text = st.text_area("Текст новости")

if st.button("Определить тональность"):

    if text.strip() == "":
        st.warning("Введите текст")
    else:
        inputs = tokenizer(
            text,
            return_tensors="pt",
            truncation=True,
            padding=True,
            max_length=512
        )

        with torch.no_grad():
            outputs = model(**inputs)

        logits = outputs.logits

        probs = torch.softmax(logits, dim=1)
        predicted_class_id = probs.argmax().item()
        confidence = probs.max().item()
        label = model.config.id2label[predicted_class_id]

        st.subheader("Результат")
        st.write("Тональность:", label)
        st.write("Уверенность:", round(confidence, 3))
```

Листинг Б.4 — Программный код для выявления тенденций

```
eps = 1e-6
topics = [col for col in topic_df.columns if "topic_" in col]
V = yearly_topics.copy()
G = V.copy()
for t in topics:
    G[t] = V[t].pct_change().replace([np.inf, -np.inf],
np.nan).fillna(0)
tmp = topic_df.copy()
tmp["year"] = df["year"].values
tmp["sentiment"] = df["new_score"].values
S_list = []
for t in topics:
    grouped = tmp.groupby("year").apply(
        lambda x: (x[t] * x["sentiment"]).sum() / (x[t].sum() +
eps)
    )
    S_list.append(grouped.rename(t))
S = pd.concat(S_list, axis=1).reset_index()
def zscore(df_mat):
    scaler = StandardScaler()
    vals = scaler.fit_transform(df_mat[topics])
    out = pd.DataFrame(vals, columns=topics)
    out["year"] = df_mat["year"].values
    return out
V_z = zscore(V)
G_z = zscore(G)
S_z = zscore(S)
w1, w2, w3 = 1/3, 1/3, 1/3
T = pd.DataFrame()
T["year"] = V["year"]
for t in topics:
    T[t] = w1 * V_z[t] + w2 * G_z[t] + w3 * S_z[t]
def classify(x):
    if x > 1:
        return "сильный рост"
    elif x > 0:
        return "умеренный рост"
    elif x > -1:
        return "снижение"
    else:
        return "сильный спад"
T_class = T.copy()
for t in topics:
    T_class[t] = T[t].apply(classify)
plt.figure(figsize=(14, 7))
```

```

def preprocess(text):
    text = str(text).lower()
    text = re.sub(r"[^a-яa-z ]", " ", text)
    text = re.sub(r"\s+", " ", text)
    words = text.split()
    words = [w for w in words if len(w) > 2]
    words = [w for w in words if w not in stop_words]
    lemmas = []
    for w in words:
        try:
            lemmas.append(morph.parse(w)[0].normal_form)
        except:
            pass
    return lemmas
df["tokens"] = df["text"].astype(str).apply(preprocess)
df = df[df["tokens"].map(len) > 5].copy()
phrases = Phrases(df["tokens"], min_count=10, threshold=15)
bigram = Phraser(phrases)
df["tokens"] = df["tokens"].apply(lambda x: bigram[x])
dictionary = corpora.Dictionary(df["tokens"])
dictionary.filter_extremes(
    no_below=15,          # минимум в 15 документах
    no_above=0.50         # максимум в 50%)
corpus = [dictionary.doc2bow(text) for text in df["tokens"]]
print("Подбор количества тем...")
scores = []
models = {}
for k in range(4, 11):    # 4..10 тем
    lda = LdaModel(
        corpus=corpus,
        id2word=dictionary,
        num_topics=k,
        random_state=42,
        passes=10,
        alpha="auto",
        eta="auto"
    )
    coherence = CoherenceModel(
        model=lda,
        texts=df["tokens"],
        dictionary=dictionary,
        coherence="c_v"
    ).get_coherence()
    scores.append((k, coherence))
    models[k] = lda
score_df = pd.DataFrame(scores, columns=["topics", "coherence"])

```